المدرسة الوطنية للعلوم التطبيقية
ⵜⵜⵍⵎⵜⴰⵏⵓⵔⵉⵜⴰⵎⴰⵏⵜⵉⴽⵉⵜ
Ecole Nationale des Sciences Appliquées de Fès

جامعة سيدي محمد بن عبدالله
ⵜⴰⵙⴷⴰⵡⵜ ⵙⵉⴷⵉ ⵎⵓⵃⴰⵎⴻⴷ ⴱⵏ ⵄⴱⴷⵍⵍⴰⵀ
Université Sidi Mohamed Ben Abdellah

# Pilotage des Flux Data SNCF :

# Intégration Talend et Reporting Avancé sous Power BI.

Réalisé par : EL BARDI SALMA
EL HAMRY NIHAD

Sous la direction de : M. MOUNTASSER IMADEDDINE

Année universitaire : 2025-2026

# Table des matières

Chapitre 1 : Introduction Générale ..... 3
1. Contexte et présentation du projet ..... 3
2. Problématique décisionnelle ..... 3
3. Objectifs et périmètre technique ..... 4
Chapitre 2 : Environnement Technologique ..... 5
1. Architecture logicielle ..... 5
2. Outils d'analyse et de visualisation ..... 6
Chapitre 3 : Mise en œuvre de la Base de Données Opérationnelle (DBO) ..... 8
1. Sources de données (Fichiers CSV) ..... 8
2. Modélisation logique de la DBO sur MySQL ..... 9
3. Processus d'ingestion et de nettoyage des données (ETL Talend) ..... 10
Chapitre 4 : Conception et Construction du Data Warehouse ..... 14
1. Modélisation multidimensionnelle : Le Schéma en Étoile ..... 14
2. Implémentation des Dimensions et de la Table de Faits ..... 15
Chapitre 5 : Migration et Analyse Multidimensionnelle avec SSAS ..... 29
1. Migration des données de MySQL vers SQL Server ..... 29
2. Création de la vue de source de données et construction du Cube ..... 34
3. Analyse avancée en langage MDX ..... 38
Chapitre 6 : Business Intelligence et Data visualisation sous Power BI ..... 42
1. Conception des Dashboards et KPI stratégiques ..... 42
2. Conception et interprétations des Dashboards ..... 45
Chapitre 7 : Conclusion et Perspectives ..... 60

# Chapitre 1 : Introduction Générale

## 1. Contexte et présentation du projet

Le secteur du transport ferroviaire génère quotidiennement une masse considérable de données transactionnelles (réservations, trajets, flux de passagers). Pour une entreprise comme la **SNCF**, la capacité à transformer ces données brutes en informations stratégiques est un avantage concurrentiel majeur.

Ce projet s'inscrit dans le cadre de la mise en place d'une **chaîne décisionnelle complète**. Il s'agit de récupérer des données de production stockées initialement dans des fichiers plats (CSV), de les structurer dans un environnement relationnel, puis de les propulser vers un système d'analyse multidimensionnel permettant un pilotage en temps réel de l'activité.

## 2. Problématique décisionnelle

La problématique de ce projet repose sur l'incapacité des systèmes transactionnels classiques à répondre aux besoins d'analyse complexe. Nous avons identifié trois verrous majeurs :

- **Le cloisonnement des données (Data Silos) :** Les informations sur les clients, les trajets et les réservations sont souvent dispersées. Sans une centralisation dans un Data Warehouse, il est impossible d'avoir une vision transversale de l'activité.
- **La performance des requêtes (OLTP vs OLAP) :** Les bases de données opérationnelles (MySQL DBO) sont conçues pour des écritures rapides (Online Transactional Processing). Tenter d'y effectuer des calculs d'agrégation massifs dégrade les performances du système. Il est donc nécessaire de migrer vers une structure multidimensionnelle (Online Analytical Processing).
- **L'intégrité et la qualité des données :** Les sources CSV sont par nature "sales" (problèmes de formats de dates, doublons, valeurs manquantes, valeurs différentes mais portant même sens comme le cas de sexe client M et H ). Le défi est de garantir que la donnée qui arrive dans le tableau de bord est 100% fiable pour le décideur.

## 3. Objectifs et périmètre technique

L'objectif central de ce projet est de concevoir une architecture robuste et évolutive. Pour ce faire, nous avons défini un périmètre technique articulé autour de quatre piliers :

1. **Architecture de la Base Opérationnelle (DBO) :** Modéliser et injecter les fichiers sources dans MySQL en appliquant des règles de gestion strictes (normalisation) via l'outil Talend Open Studio.

2. **Modélisation Multidimensionnelle (DW) :** Concevoir un entrepôt de données structuré en schéma en étoile. Ce choix est motivé par la simplicité des jointures et l'efficacité des performances lors de l'interrogation de la table de faits ventes.

3. **Analyse et Migration vers l'écosystème Microsoft :** Pour bénéficier de la puissance du traitement analytique, nous migrons les données vers SQL Server. L'objectif est de construire un cube SSAS permettant des calculs pré-agrégés et d'utiliser le langage MDX pour manipuler des dimensions temporelles et géographiques complexes.

4. **Reporting et Data Visualisation :** Développer un environnement de restitution sous Power BI. L'objectif est de transformer les mesures en indicateurs de performance (KPI) visuels et interactifs.

En résumé, ce projet consiste à concevoir une architecture décisionnelle de bout en bout pour le secteur ferroviaire, en utilisant les outils Talend, MySQL, SSAS et Power BI. L'objectif est de transformer des données transactionnelles brutes en un Data Warehouse structuré, capable de surmonter les défis de la qualité des données, du cloisonnement des systèmes et de l'optimisation des performances analytiques. En normalisant les flux et en migrant vers un environnement multidimensionnel, ce projet vise à fournir des indicateurs stratégiques fiables pour un pilotage précis de l'activité.

# Chapitre 2 : Environnement Technologique

Le succès d'un projet décisionnel repose sur la cohérence de sa chaîne technique. Pour ce projet, nous avons opté pour une architecture hybride, alliant la flexibilité de l'Open Source pour l'intégration et la puissance de l'écosystème Microsoft pour l'analyse.

## 1. Architecture logicielle

L'architecture de ce projet repose sur une chaîne de traitement hybride où **MySQL** sert de pivot central pour le stockage et la visualisation, tandis que **SQL Server** intervient spécifiquement pour l'analyse multidimensionnelle complexe.

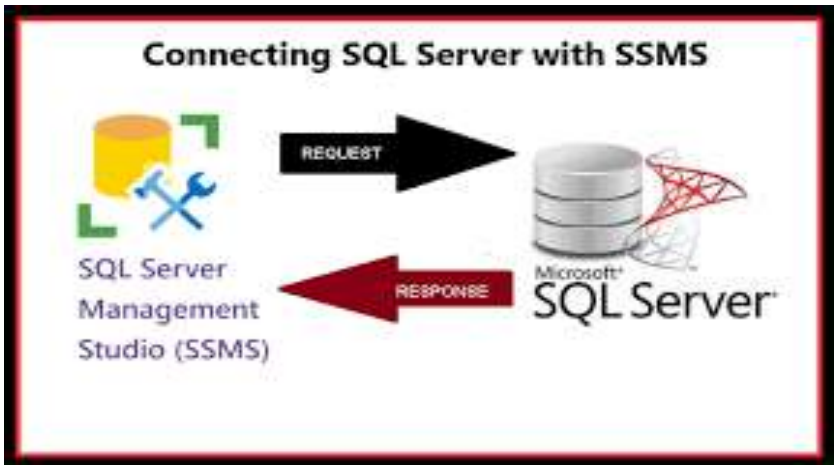
- **Talend Open Studio (ETL) :** Pivot central de l'intégration, cet outil a été utilisé pour l'extraction des fichiers **CSV**, le nettoyage rigoureux des données (gestion des formats de dates, normalisation des genres) et le chargement vers les bases de données.




- **MySQL (SGBDR & DW) :** Il constitue le socle de stockage principal. MySQL héberge à la fois la base de données opérationnelle et le **Data Warehouse**. C'est également la source de données principale pour la partie visualisation.



- **SQL Server & SQL Server Management Studio (SSMS)** : Cet environnement a été déployé pour héberger la structure nécessaire aux analyses multidimensionnelles. SSMS a permis de gérer le stockage des données migrées et de configurer la base de données relationnelle avant son passage en mode multidimensionnel.




- **Visual Studio (SSDT) :** C'est l'environnement de développement intégré (IDE) utilisé pour la conception technique du projet. Il a permis de créer le projet **Analysis Services**, de définir la source de données et de construire la structure logique du cube OLAP.



## 2. Outils d'analyse et de visualisation

• **SQL Server Analysis Services (SSAS) :** C'est le moteur analytique utilisé pour passer d'une vision relationnelle à une vision multidimensionnelle. Contrairement à une base SQL classique, **SSAS** permet de créer un **Cube OLAP** où les données sont pré-agrégées selon plusieurs axes. Cette technologie est indispensable pour garantir des temps de réponse instantanés lors de l'analyse de gros volumes de données ferroviaires.




- **Le langage MDX :** Au sein du cube, nous avons utilisé le langage **MDX**. Ce langage est spécifique à l'analyse multidimensionnelle ,qu'un langage SQL standard ne pourrait pas traiter avec la même efficacité .

- **Power BI Desktop :** C'est l'outil de restitution finale et de **Business Intelligence**. Dans notre architecture, Power BI est **directement connecté au Data Warehouse MySQL**. Ce choix permet de transformer les tables de faits et de dimensions en tableaux de bord visuels et interactifs. Grâce aux fonctionnalités de filtrage dynamique et de "Drill-down", Power BI offre aux décideurs une exploration intuitive des données, allant d'une vue globale du chiffre d'affaires jusqu'au détail d'un trajet spécifique.



# Chapitre 3 : Mise en œuvre de la Base de Données Opérationnelle (DBO)

Ce chapitre détaille la phase cruciale de l'ingestion. Avant de pouvoir analyser les données, il a fallu transformer un ensemble de fichiers plats hétérogènes en une base de données relationnelle structurée et fiable sous MySQL

## 1. Sources de données (Fichiers CSV)

### *Inventaire et Volumétrie*

Les données sont réparties sur plusieurs fichiers représentant les entités clés du système ferroviaire :

**Réservations :** Un ensemble de **5 fichiers** totalisant environ **10 millions de lignes** (2 millions par fichier). C'est le cœur transactionnel du projet.

**Trajets :** Un ensemble de **5 fichiers** représentant environ **6 millions de lignes** (1,2 million par fichier). Ils détaillent les liaisons entre les gares.

**Clients :** Un fichier de **100 000 lignes**, contenant les informations sociodémographiques.

**Trains :** Un fichier de référence de **2 500 lignes** listant le parc matériel et ses caractéristiques techniques.

**Gares :** Un fichier de **198 lignes** répertoriant les points d'arrêt et leur localisation.

### *Compréhension du schéma et typage*

Au-delà de la quantité, un travail d'analyse sémantique a été nécessaire pour chaque colonne. Avant toute création de base de données, nous avons dû :

1. Analyser le format des fichiers : Identifier le délimiteur et l'encodage des caractères (UTF-8).
2. Définir le schéma : Identifier les relations entre les fichiers (ex: le lien entre l'ID trajet dans le fichier réservation et le fichier trajet).
3. Déterminer les types de données : Il a fallu distinguer les entiers (ID), les chaînes de caractères, et surtout les types Date et leur patterns particulièrement sensibles dans les fichiers SNCF.

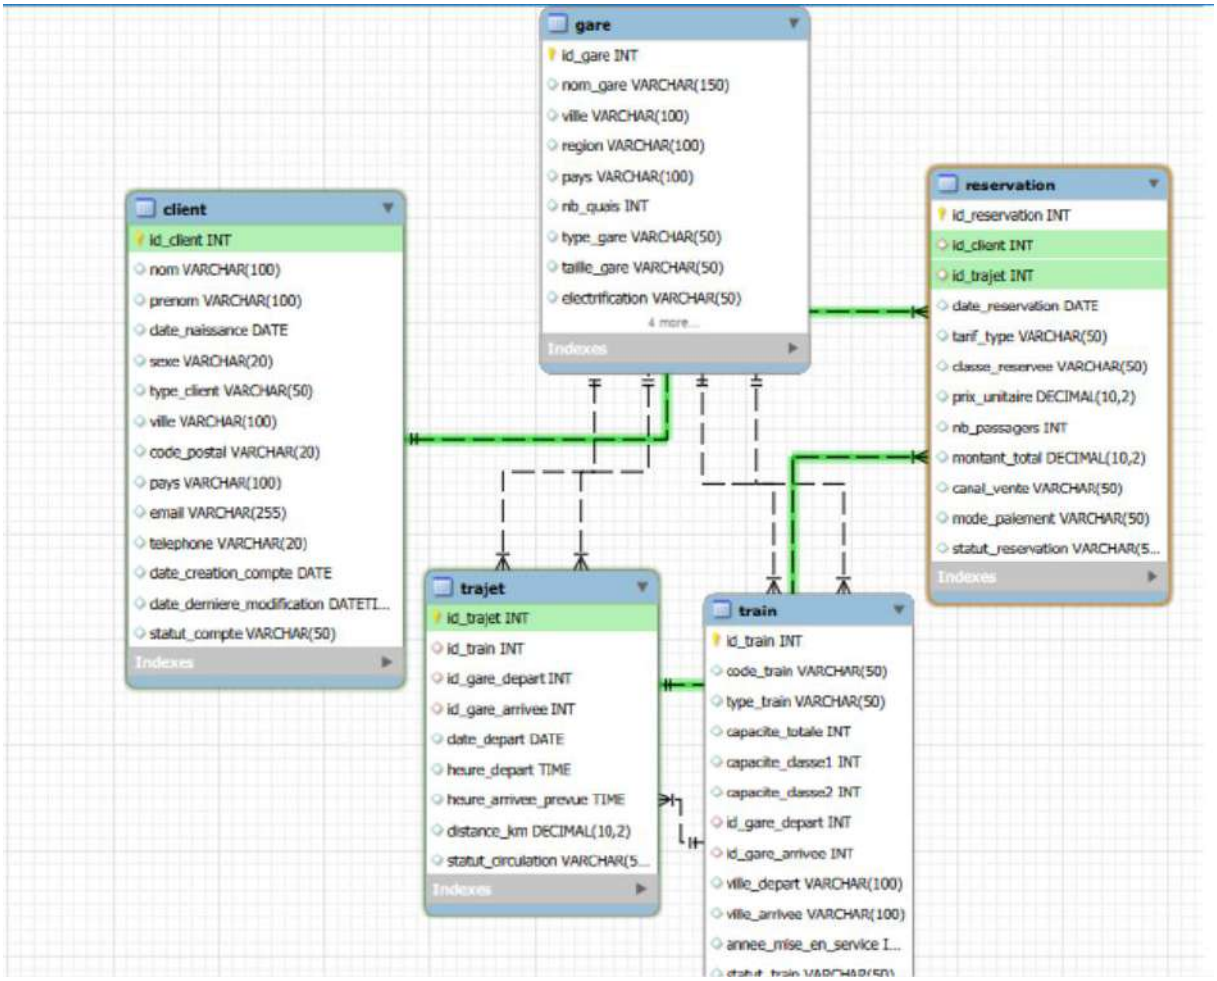
   Cette compréhension approfondie est indispensable pour concevoir une Database Opérationnelle adéquate. Sans cette étude préalable du schéma et des types de colonnes,

nous risquerions des pertes de données lors de l'insertion ou des erreurs de jointures catastrophiques pour la phase analytique ultérieure. Cette étape a également permis d'anticiper les futurs besoins de nettoyage que nous traiterons via Talend.

## 2. Modélisation logique de la DBO sur MySQL

- Schéma Relationnel (EER)

La conception de la **Base de Données Opérationnelle (DBO)** repose sur un modèle relationnel normalisé, structuré pour assurer l'intégrité des données SNCF avant leur exploitation décisionnelle. Le schéma s'articule autour de tables de référence (référentiels) et de tables transactionnelles. Les référentiels **client**, **gare** et **train** stockent les informations statiques, tandis que les tables **trajet** et **reservation** capturent la dynamique du système, reliant les infrastructures aux services de transport et aux transactions commerciales.



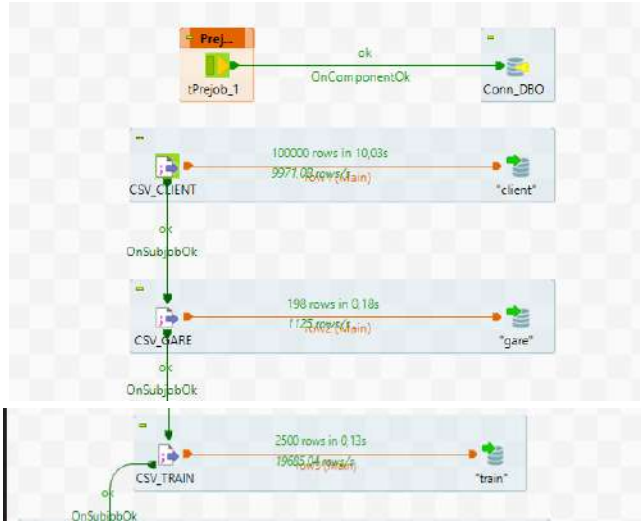
Le cœur de cette modélisation réside dans la gestion des dépendances fonctionnelles. La table **trajet** joue un rôle pivot : elle lie chaque service ferroviaire à un matériel spécifique via la table **train** et définit l'itinéraire en pointant doublement vers la table **gare** (pour le départ et l'arrivée). Cette structure garantit que chaque voyage est physiquement cohérent. Par la suite, la table **reservation** vient se greffer sur ce socle en créant un lien direct entre un client unique et un trajet précis. Cette hiérarchie permet d'éviter toute redondance : une modification sur une caractéristique de train ou le nom d'une gare se propage automatiquement à l'ensemble des réservations associées.

L'intégrité du système est verrouillée par des relations de type **1:N (un-à-plusieurs)** et des contraintes de clés étrangères rigoureuses. Par exemple, un client peut effectuer plusieurs réservations, mais chaque ligne de réservation est strictement rattachée à un seul identifiant client. De même, un trajet peut accueillir des centaines de passagers, mais il est limité par la capacité du train défini dans le référentiel matériel. Ce schéma EER assure ainsi une base saine et cohérente, indispensable pour la phase de nettoyage ETL et la construction ultérieure du Data Warehouse.

# 3. Processus d'ingestion et de nettoyage des données (ETL Talend)

L'étape d'ingestion est le moteur de notre architecture. Pour transformer les millions de lignes de fichiers CSV en données structurées dans notre DBO MySQL, nous avons développé un job **Talend** optimisé, capable de gérer la volumétrie et d'assurer la qualité des informations

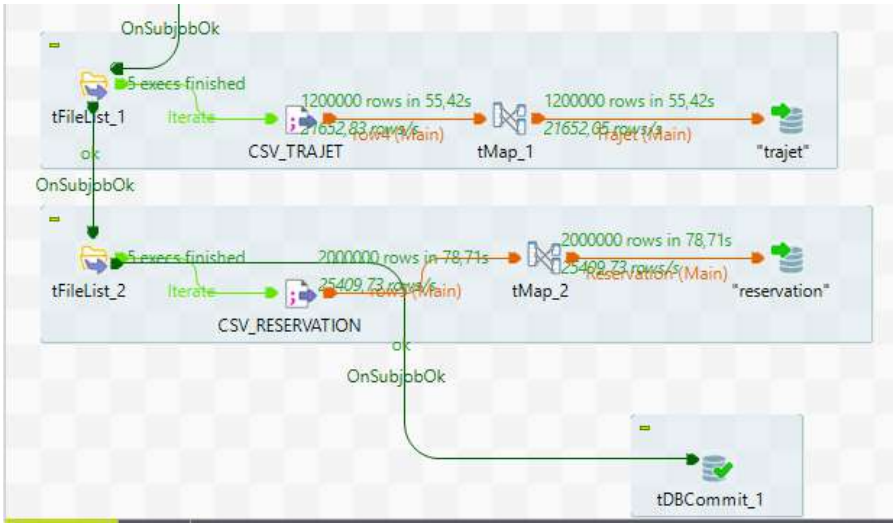
Le job débute par une phase de pré-traitement via le composant **tPrejob**. Cette étape permet d'établir une connexion unique et persistante vers la base de données MySQL (**tDBConnection**). L'objectif est d'optimiser les performances en évitant d'ouvrir et de fermer une connexion pour chaque fichier traité. En fin de processus, un **tDBCommit** assure la validation de toutes les transactions, garantissant l'intégrité des données insérées.




La gestion des fichiers **Trajets** et **Réservations** (plusieurs fichiers par entité) a été automatisée grâce au composant **tFileList**.

Ce composant scanne le répertoire source et itère sur chaque fichier correspondant à un masque (ex: RESERVATION_*.csv).

L'avantage majeur de cette approche est qu'en cas d'ajout d'un nouveau fichier (par exemple l'année 2026), il suffit de relancer le job. Le système intégrera automatiquement les nouvelles données sans aucune modification du code ou de la structure du job.




L'ingestion des millions de lignes ne peut se faire de manière aléatoire. Comme nous l'avons vu dans la modélisation EER, il existe des liens de parenté stricts entre les tables. Par exemple, il est physiquement impossible d'insérer une ligne dans la table **reservation** si le trajet (id_trajet) ou le client (id_client) correspondant n'existe pas encore dans la base de données.

Pour garantir le respect de ces contraintes d'intégrité, nous avons utilisé le lien **"OnSubjobOK"** de Talend :

- ✓ **Séquençage logique :** Le job est découpé en plusieurs étapes séquentielles. Nous commençons par l'ingestion des référentiels "parents" (**Gares**, **Trains**, puis **Clients**).
- ✓ **Sécurité de l'ingestion :** Ce n'est qu'une fois que ces sous-jobs sont terminés avec succès que le lien **OnSubjobOK** déclenche l'ingestion des tables "enfants" (**Trajets**, puis enfin **Réservations**).
- ✓ **Fiabilité :** Cette méthode évite les erreurs de violation de clés étrangères (FK) qui bloqueraient le processus. Si l'ingestion d'un référentiel échoue, le processus s'arrête immédiatement, empêchant ainsi la création de données "orphelines" dans la DBO.

Une fois le job exécuté, nous avons procédé à une vérification directe dans **MySQL Workbench**. Les captures suivantes montrent un échantillon des données correctement intégrées dans leurs tables respectives :

- **Table client**

```
5 •  SELECT * FROM sncf_dbo.client LIMIT 10;
```

Result Grid | Filter Rows: | Edit: | Export/Import: | Wrap Cell Content: | Fetch rows:

| id_client | nom | prenom | date_naissance | sexe | type_client | ville | code_postal | pays | email |
|---|---|---|---|---|---|---|---|---|---|
| 1 | Martin | Chloe | 1956-03-12 | F | particulier | Lille | 62678 | France | chloe.martin1@example |
| 2 | Thomas | Sophie | 1992-03-03 | F | particulier | STRASBOURG | 80453 | France | sophie.thomas2@exam |
| 3 | Richard | Camille | 1990-03-04 | Femme | particulier | Bordeaux | 73532 | France | camille.richard3@examp |
| 4 | Leroy | Louis | 1956-03-12 | H | professionnel | nantes | 74127 | France | louis.leroy4@example.c |
| 5 | Dubois | Lucas | 2005-02-28 | M | professionnel | Lyon | 36559 | Espagne | lucas.dubois5@example |
| 6 | Thomas | Julien | 1958-03-12 | M | particulier | Bordeaux | 11306 | France | julien.thomas6@exampl |
| 7 | Dubois | Antoine | 1955-03-13 | M | particulier | Lyon | 93080 | France | antoine.dubois7@exam |

Hétérogénéité des valeurs de genre, nous remarquons que la donnée n'est pas uniformisée. Par exemple, le genre masculin est parfois exprimé par la lettre "M", parfois par "H" ou même Homme.

**Note :** Si cette remarque n'est pas prise en compte lors de l'ingestion, dans l'entrepôt de données le système traiterait ces valeurs comme des catégories distinctes, ce qui diviserait artificiellement la population masculine dans nos futurs rapports.

- **Table reservation :**

```
1    -- La table centrale pour ton tmap (main)
2 •  SELECT * FROM sncf_dbo.reservation LIMIT 10;
3
4    -- SELECT * FROM sncf_dbo.client LIMIT 10;
5    -- SELECT * FROM sncf_dbo.gare LIMIT 10;
```

| id_reservation | id_client | id_trajet | date_reservation | tarif_type | classe_reservee | prix_unitaire | nb_passagers | montant_total |
|---|---|---|---|---|---|---|---|---|
| 1 | 33363 | 1007844 | 2021-04-28 | Jeune | 1ère | 46.57 | 4 | 186.28 |
| 2 | 41386 | 621758 | 2021-05-16 | Plein | 2nde | 141.73 | 1 | 141.73 |
| 3 | 69566 | 713055 | 2020-10-13 | Plein | 1ère | 109.21 | 4 | 436.84 |
| 4 | 84040 | 429718 | 2021-09-04 | Business | 1ère | 16.51 | 3 | 49.53 |
| 5 | 97092 | 1047572 | 2021-05-18 | Plein | 2nde | 122.84 | 4 | 491.36 |
| 6 | 24777 | 953681 | 2021-01-16 | Business | 2nde | 12.68 | 4 | 50.72 |

- **Table trajet :**

```
8 •  SELECT * FROM sncf_dbo.trajet LIMIT 10;
```

| id_trajet | id_train | id_gare_depart | id_gare_arrivee | date_depart | heure_depart | heure_arrivee_prevue | distance_km | statut_circu |
|---|---|---|---|---|---|---|---|---|
| 1 | 1141 | 4 | 6 | 2021-09-25 | 08:35:00 | 09:27:00 | 241.00 | réalisé |
| 2 | 2106 | 98 | 23 | 2021-05-12 | 17:39:00 | 03:28:00 | 182.00 | prévu |
| 3 | 1153 | 58 | 6 | 2021-12-28 | 15:30:00 | 16:37:00 | 68.00 | réalisé |
| 4 | 2007 | 73 | 192 | 2021-03-06 | 14:39:00 | 20:30:00 | 1176.00 | réalisé |
| 5 | 2093 | 197 | 40 | 2021-03-03 | 21:54:00 | 06:29:00 | 675.00 | réalisé |
| 6 | 1536 | 146 | 178 | 2021-03-19 | 17:25:00 | 20:43:00 | 303.00 | réalisé |
| 7 | 831 | 41 | 168 | 2021-03-10 | 01:35:00 | 07:30:00 | 847.00 | réalisé |

- **Table gare :**

```
6 •  SELECT * FROM sncf_dbo.gare LIMIT 10;
```

| id_gare | nom_gare | ville | region | pays | nb_quais | type_gare | taille_gare | electrification | annee_mise_en_service |
|---|---|---|---|---|---|---|---|---|---|
| 1 | Gare Paris 1 | Paris | Île-de-France | France | 23 | Mixte | Grande | Electrifiée | 1951 |
| 2 | Gare Paris 2 | Paris | Île-de-France | France | 23 | Mixte | Grande | Electrifiée | 1988 |
| 3 | Gare Paris 3 | Paris | Île-de-France | France | 29 | Mixte | Grande | Electrifiée | 1933 |
| 4 | Gare Paris 4 | Paris | Île-de-France | France | 23 | Mixte | Grande | Electrifiée | 2011 |
| 5 | Gare Paris 5 | Paris | Île-de-France | France | 36 | Mixte | Grande | Electrifiée | 2010 |
| 6 | Gare Paris 6 | Paris | Île-de-France | France | 32 | Mixte | Grande | Electrifiée | 1984 |

- **Table train :**

```
•  SELECT * FROM sncf_dbo.train LIMIT 10;
```

| id_train | code_train | type_train | capacite_totale | capacite_classe1 | capacite_classe2 | id_gare_depart | id_gare_arrivee | ville_depar |
|---|---|---|---|---|---|---|---|---|
| 1 | TR-000001 | TGV | 448 | 134 | 314 | 73 | 15 | Nantes |
| 2 | TR-000002 | TGV | 528 | 130 | 370 | 42 | 173 | Marseille |
| 3 | TR-000003 | TGV | 487 | 146 | 341 | 188 | 53 | Milan |
| 4 | TR-000004 | TGV | 546 | 163 | 383 | 17 | 56 | Lyon |
| 5 | TR-000005 | TER | 148 | 14 | 134 | 121 | 168 | Rennes |
| 6 | TR-000006 | TGV | 561 | 168 | 393 | 18 | 155 | Lyon |

# Chapitre 4 : Conception et Construction du Data Warehouse

## 1. Modélisation multidimensionnelle : Le Schéma en Étoile

Le **Data Warehouse** est conçu spécifiquement pour l'analyse et la prise de décision. Il se distingue de la **Base de Données Opérationnelle (DBO)** par sa finalité :

**DB Opérationnelle (OLTP) :** Orientée vers les transactions quotidiennes. Elle doit être rapide en écriture, éviter les redondances (normalisation) et garantir l'intégrité des données en temps réel.

**Data Warehouse (OLAP) :** Orienté vers l'analyse historique et massive. Il est optimisé pour la lecture. On y stocke des données consolidées et souvent dénormalisées pour obtenir des réponses rapides aux requêtes complexes.

**Note sur l'hébergement :** En environnement industriel, il est courant d'héberger la DBO et le DW sur des serveurs ou SGBD différents afin de ne pas saturer les ressources lors de l'extraction des rapports. Dans le cadre de ce projet, pour des raisons de simplicité et de centralisation, nous avons choisi d'héberger les deux environnements sous **MySQL**, en les isolant par des schémas distincts.

### *Choix du schéma : Étoile vs Flocon de neige*

Il existe deux manières principales de structurer un Data Warehouse :

**Schéma en Étoile (Star Schema) :** Les dimensions sont directement reliées à la table de faits. Elles sont dénormalisées (une seule table par axe d'analyse).

*Avantage :* Requêtes très rapides ,peu de jointures et grande simplicité de navigation.

**Schéma en Flocon de Neige :** Les dimensions sont elles-mêmes normalisées ,divisées en sous-tables.

*Avantage :* Économie d'espace disque et meilleure intégrité des dimensions. Cependant, il ralentit les requêtes à cause de la multiplication des jointures.

**Choix du projet :** Nous avons opté pour le **Schéma en Étoile**. Dans un contexte décisionnel comme celui de la SNCF, la vitesse de calcul des KPI est prioritaire sur l'optimisation de l'espace disque.

### *Structure des Tables de Faits*

Une table de faits représente un processus métier. Dans notre cas, nous avons implémenté une table de faits unique centrée sur les **Ventes/Réservations**.
Toutefois, dans un environnement métier complet, un Data Warehouse peut contenir plusieurs tables de faits interconnectées selon les besoins analytiques :
**Fait_Ventes :** Pour l'analyse du chiffre d'affaires et de la clientèle.
**Fait_Maintenance :** Pour analyser la fiabilité des rames et les coûts de réparation des trains.
**Fait_RH :** Pour le suivi des employés (conducteurs, contrôleurs) et la gestion des plannings.
L'utilisation d'une table de faits unique pour ce projet nous permet de nous concentrer sur l'objectif principal : le pilotage de la performance commerciale.

# 2. Implémentation des Dimensions et de la Table de Faits

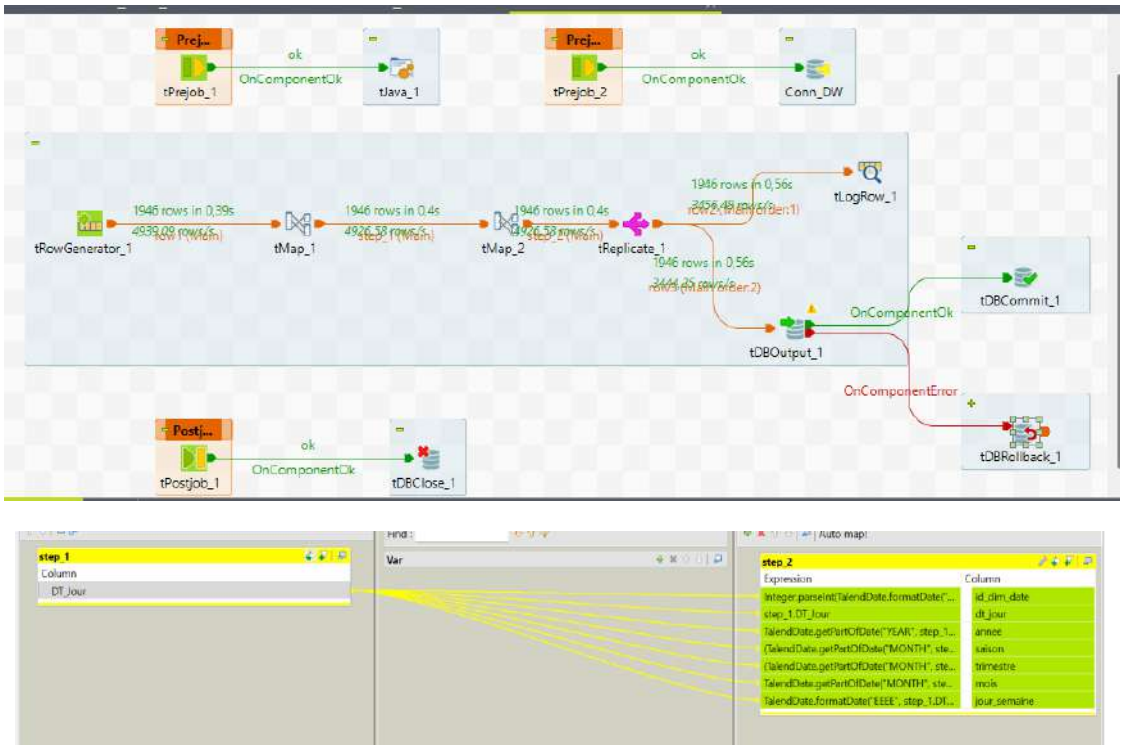
Une fois la modélisation théorique en étoile validée, nous avons procédé à l'implémentation physique du Data Warehouse à l'aide de **Talend Open Studio**. Cette phase consiste à alimenter les tables du DW à partir des données nettoyées de la DBO, tout en transformant les relations métier en une structure optimisée pour l'analyse multidimensionnelle.

L'implémentation du Data Warehouse sous Talend repose sur une stratégie de chargement ordonnée, visant à transformer le modèle relationnel de la DBO en un modèle multidimensionnel optimisé. Pour ce faire, nous avons créé une série de jobs ETL dédiés à l'alimentation de chaque dimension : **dim_client**, **dim_train**, **dim_date, dim_gare**,ainsi que les dimensions de référence telles que **dim_tarif**, **dim_canal_vente**, **dim_mode_paiement**, **dim_classe_reservation** et **dim_statut_reservation**.
L'objectif technique de ces jobs est double : d'une part, isoler les attributs descriptifs de chaque entité, et d'autre part, générer des **clés techniques (Surrogate Keys)** auto-incrémentées. Ces clés sont essentielles car elles serviront de points d'ancrage pour la table de faits centrale.
La table de faits **f_ventes** est ensuite alimentée en dernier lieu. Elle agit comme un réceptacle collectant les clés techniques de toutes les dimensions grâce à des jointures de type "Lookup" dans le **tMap**. Cette structure permet à la table de faits de rester légère et performante, ne contenant que des références numériques vers les dimensions et les mesures quantitatives (prix, nombre de passagers, montant total), préparant ainsi parfaitement le terrain pour l'analyse sous Power BI et le langage MDX.

*Dim_Date :*

L'implémentation de la dimension temporelle constitue une étape stratégique du projet, car elle permet de structurer l'analyse de la performance ferroviaire selon des axes de saisonnalité précis.

Contrairement aux autres entités, cette table est générée de manière autonome via un job Talend spécifique utilisant le composant tRowGenerator pour créer une séquence chronologique continue. À travers une succession de composants tMap, nous exploitons des fonctions Java avancées pour décomposer chaque date en plusieurs attributs analytiques riches, tels que le trimestre, le mois, le jour de la semaine et la saison, garantissant ainsi une granularité d'analyse optimale pour les futurs rapports décisionnels.







Le résultat obtenu dans le Data Warehouse témoigne de la réussite de ce flux de transformation, avec une table parfaitement structurée où chaque entrée est identifiée par une clé primaire intelligente. Cette organisation permet de convertir une simple donnée temporelle brute en un levier de pilotage puissant, capable de répondre à des problématiques métier complexes comme l'identification des pics de fréquentation hebdomadaires ou l'impact des saisons sur le volume des réservations.

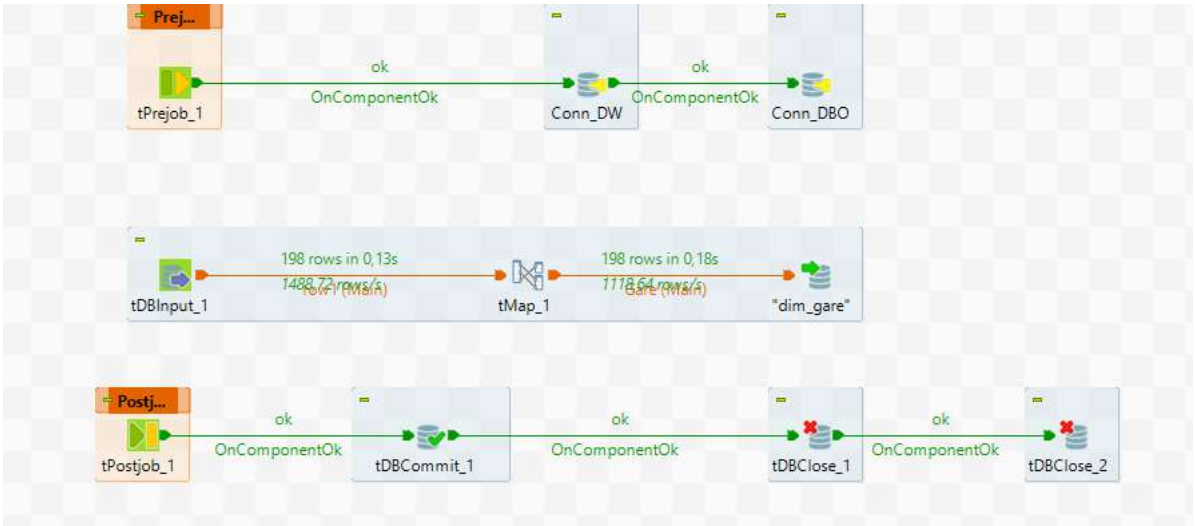
```
1 •    SELECT * FROM sncf_dw.dim_date;
```

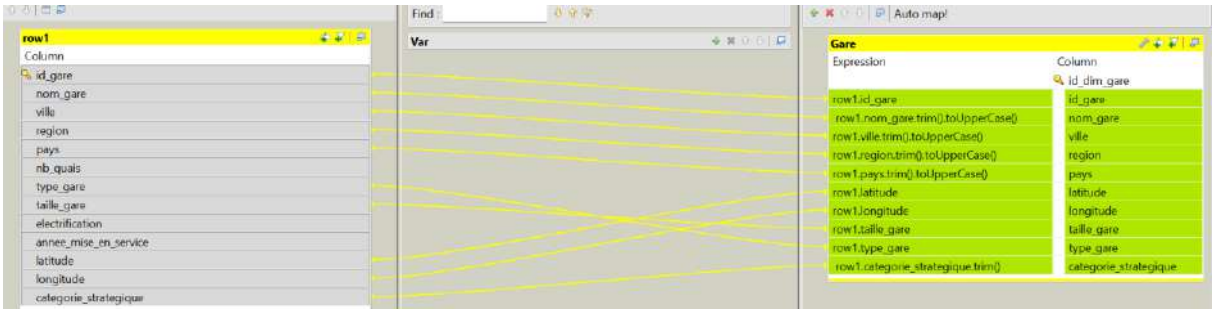
Result Grid | Filter Rows: | Edit: | Export/Import:

| id_dim_date | dt_jour | annee | mois | trimestre | saison | jour_semaine |
|---|---|---|---|---|---|---|
| 20200901 | 2020-09-01 | 2020 | 9 | 3 | Été | mardi |
| 20200902 | 2020-09-02 | 2020 | 9 | 3 | Été | mercredi |
| 20200903 | 2020-09-03 | 2020 | 9 | 3 | Été | jeudi |
| 20200904 | 2020-09-04 | 2020 | 9 | 3 | Été | vendredi |
| 20200905 | 2020-09-05 | 2020 | 9 | 3 | Été | samedi |
| 20200906 | 2020-09-06 | 2020 | 9 | 3 | Été | dimanche |
| 20200907 | 2020-09-07 | 2020 | 9 | 3 | Été | lundi |

### *Dim_gare*

L'implémentation de la dimension **Gare** (dim_gare) repose sur la transformation des données géographiques afin de fournir un axe d'analyse spatial précis pour le réseau ferroviaire. Le job Talend dédié extrait les informations de la base opérationnelle et utilise un composant **tMap** pour assurer le passage vers le modèle multidimensionnel. Lors de cette étape, nous appliquons des fonctions de nettoyage systématiques, telles que trim() et toUpperCase(), pour normaliser les noms des villes et des gares. Ce traitement garantit une uniformité parfaite des données, éliminant les espaces inutiles et les variations de casse qui pourraient fragmenter les analyses lors de la phase de visualisation.






Le résultat final dans le Data Warehouse présente un référentiel enrichi où chaque gare est identifiée par une clé technique unique (id_dim_gare), tout en conservant son identifiant métier d'origine. Outre les informations de localisation classiques comme la région ou les coordonnées GPS (latitude et longitude), nous avons intégré des attributs stratégiques tels que la taille et le type de la gare. Cette structure permet aux décideurs de filtrer les performances commerciales non seulement par zone géographique, mais aussi par catégorie d'infrastructure, offrant ainsi une vision détaillée de l'activité ferroviaire sur l'ensemble du territoire.

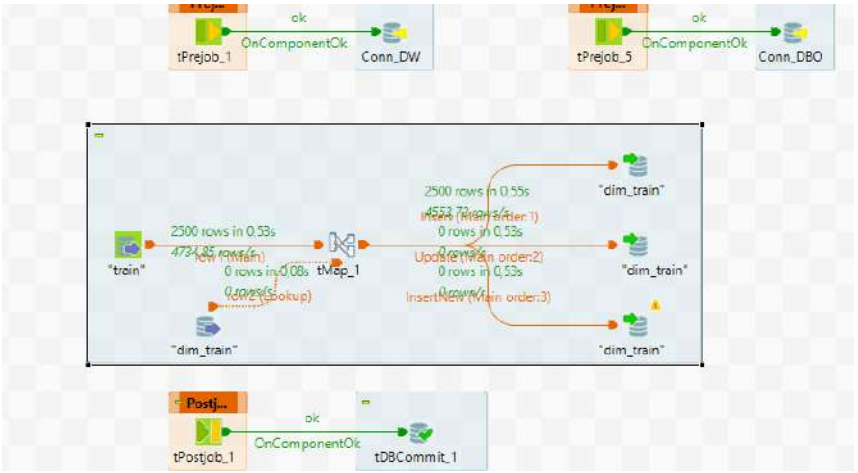
Result Grid | Filter Rows: | Edit: | Export/Import: | Wrap Cell Content:

| id_dim_gare | id_gare | nom_gare | ville | region | pays | latitude | longitude | taille_gare | type_gare |
|---|---|---|---|---|---|---|---|---|---|
| 1 | 1 | GARE PARIS 1 | PARIS | ÎLE-DE-FRANCE | FRANCE | 48.87184800 | 2.36829800 | Grande | Mixte |
| 2 | 2 | GARE PARIS 2 | PARIS | ÎLE-DE-FRANCE | FRANCE | 48.86783800 | 2.36977500 | Grande | Mixte |
| 3 | 3 | GARE PARIS 3 | PARIS | ÎLE-DE-FRANCE | FRANCE | 48.87510600 | 2.36405600 | Grande | Mixte |
| 4 | 4 | GARE PARIS 4 | PARIS | ÎLE-DE-FRANCE | FRANCE | 48.87443000 | 2.33353100 | Grande | Mixte |
| 5 | 5 | GARE PARIS 5 | PARIS | ÎLE-DE-FRANCE | FRANCE | 48.85180200 | 2.35546900 | Grande | Mixte |
| 6 | 6 | GARE PARIS 6 | PARIS | ÎLE-DE-FRANCE | FRANCE | 48.86246700 | 2.36272800 | Grande | Mixte |
| 7 | 7 | GARE PARIS 7 | PARIS | ÎLE-DE-FRANCE | FRANCE | 48.85942100 | 2.33762100 | Grande | Mixte |
| 8 | 8 | GARE PARIS 8 | PARIS | ÎLE-DE-FRANCE | FRANCE | 48.85678800 | 2.34447700 | Grande | Mixte |
| 9 | 9 | GARE PARIS 9 | PARIS | ÎLE-DE-FRANCE | FRANCE | 48.86688700 | 2.36336000 | Grande | Mixte |

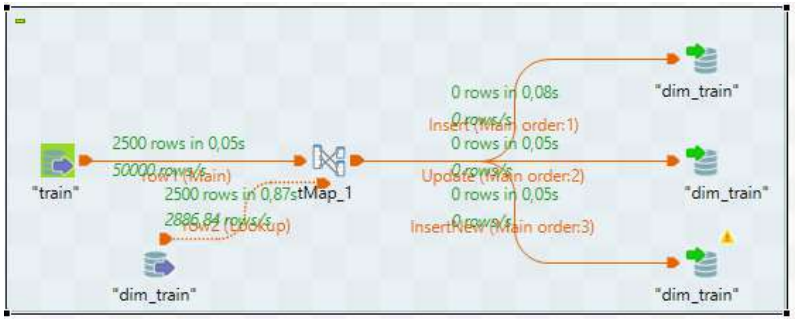
### *Dim_train*

L'implémentation de la dimension Train (dim_train) se distingue par l'utilisation d'une logique de SCD (Slowly Changing Dimension), permettant de gérer l'évolution des caractéristiques du matériel roulant au fil du temps. Grâce à une structure de job intelligente sous Talend, le flux est capable de distinguer automatiquement les nouveaux enregistrements des mises à jour techniques. En utilisant un composant tMap configuré avec plusieurs sorties, nous isolons les nouveaux trains pour une insertion directe tout en identifiant les modifications sur les trains existants pour une mise à jour de la dimension, garantissant ainsi un référentiel toujours à jour sans duplication d'informations.

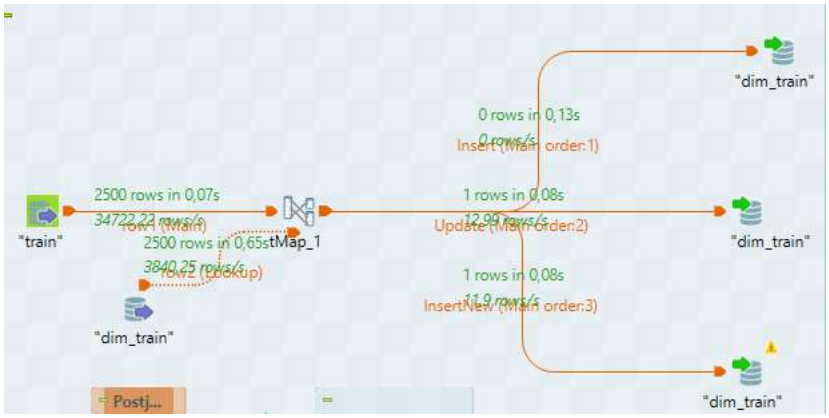
Le processus est conçu pour être résilient et auto-suffisant lors de chaque exécution. En cas de première insertion, le job remplit la dimension à partir des données sources brutes.

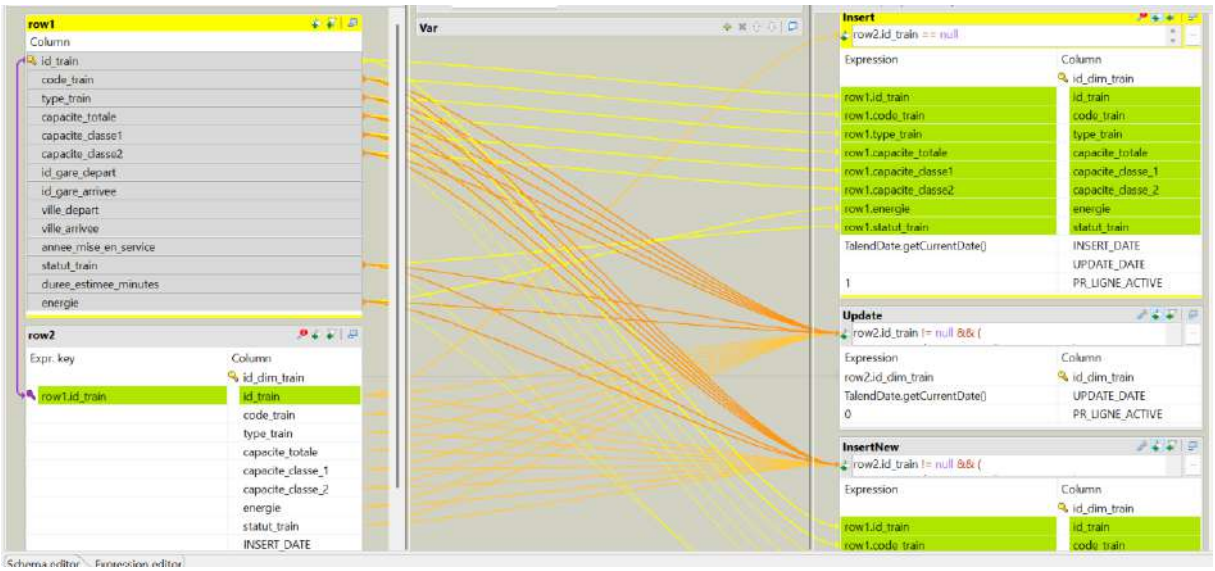



Si le job est relancé alors que les données sont déjà présentes et inchangées, un mécanisme de détection de doublons bloque toute insertion redondante, préservant ainsi l'intégrité de la base.

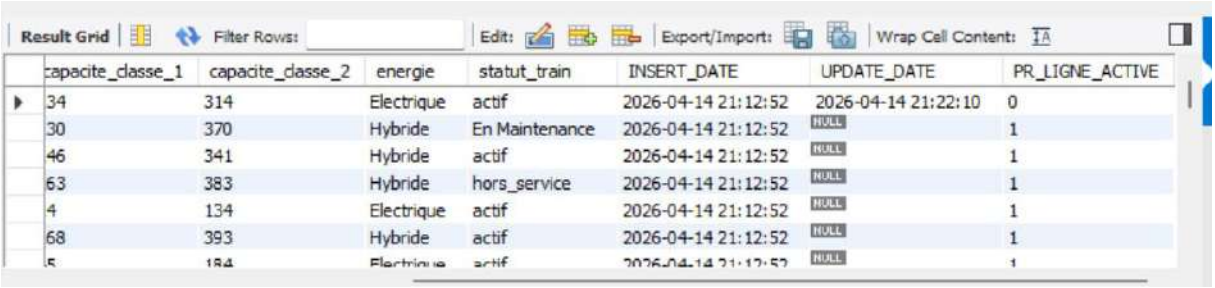



En revanche, si une modification est détectée sur un attribut le flux dirige ces lignes vers une sortie de mise à jour dédiée. Cette approche permet de maintenir une traçabilité parfaite des actifs ferroviaires tout en optimisant les performances de stockage dans le Data Warehouse.






Le cœur de ce processus réside dans le composant **tMap**, qui effectue une comparaison en temps réel entre les données entrantes de la DBO et celles déjà présentes dans le Data Warehouse. Grâce à une jointure de type *Lookup*, le système identifie instantanément si un train est une nouvelle acquisition, une donnée déjà existante ou une entité ayant subi une modification technique, permettant ainsi d'orienter chaque ligne vers le flux de traitement approprié.



Result Grid | Filter Rows: | Edit: | Export/Import: | Wrap Cell Content:

| capacite_classe_1 | capacite_classe_2 | energie | statut_train | INSERT_DATE | UPDATE_DATE | PR_LIGNE_ACTIVE |
|---|---|---|---|---|---|---|
| 34 | 314 | Electrique | actif | 2026-04-14 21:12:52 | 2026-04-14 21:22:10 | 0 |
| 30 | 370 | Hybride | En Maintenance | 2026-04-14 21:12:52 | NULL | 1 |
| 46 | 341 | Hybride | actif | 2026-04-14 21:12:52 | NULL | 1 |
| 63 | 383 | Hybride | hors_service | 2026-04-14 21:12:52 | NULL | 1 |
| 4 | 134 | Electrique | actif | 2026-04-14 21:12:52 | NULL | 1 |
| 68 | 393 | Hybride | actif | 2026-04-14 21:12:52 | NULL | 1 |
| 5 | 184 | Electrique | actif | 2026-04-14 21:12:52 | NULL | 1 |

Chaque ligne de la table résultante présente des attributs propres tels que le modèle du train et sa capacité maximale, associés à une clé primaire technique unique. Ce résultat propre et structuré est indispensable pour les analyses de rentabilité par trajet, car il permet de croiser avec précision le type de matériel utilisé avec le nombre de réservations effectives

### *dim_client*

L'implémentation de la dimension Client (dim_client) repose sur une logique de transformation avancée visant à enrichir les données sociodémographiques pour une analyse comportementale fine.



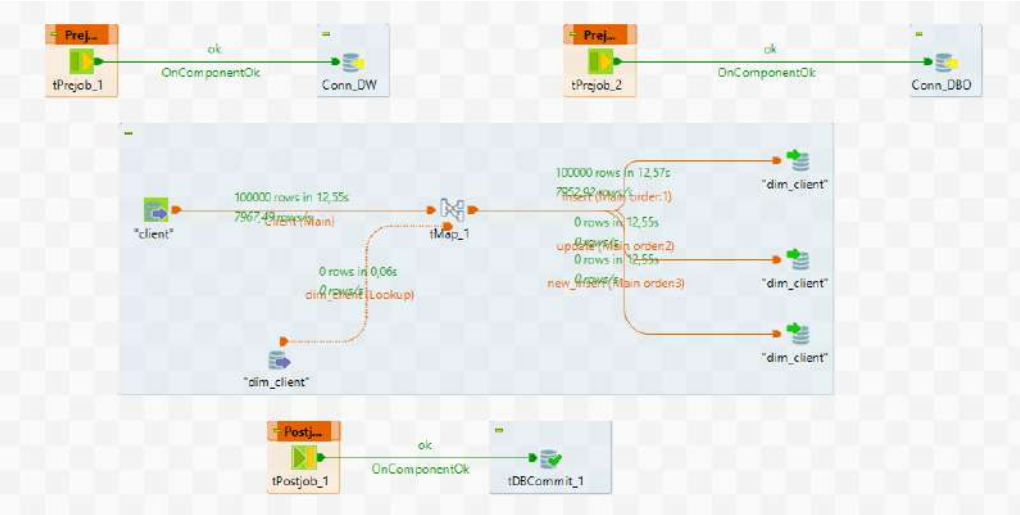

```
Var.age < 12 ? "Enfant" :
(Var.age < 18 ? "Jeune" :
(Var.age < 35 ? "Jeune Adulte" :
(Var.age < 65 ? "Adulte" :
"Senior")))
```

Dans le composant tMap, nous avons mis en place des variables calculées pour déterminer l'âge des clients à partir de leur date de naissance, ce qui a permis de générer automatiquement une tranche d'âge (Enfant, Jeune, Adulte, Senior).

```
Client.sexe == null ? "Inconnu" :
(Client.sexe.trim().equalsIgnoreCase("f") || Client.sexe.trim().equalsIgnoreCase("femme"))
? "FEMME" :
(Client.sexe.trim().equalsIgnoreCase("h") || Client.sexe.trim().equalsIgnoreCase("m") ||
Client.sexe.trim().equalsIgnoreCase("homme")) ? "HOMME" :
"Inconnu"
```

Parallèlement, un nettoyage rigoureux a été appliqué à la colonne sexe via des conditions Java, afin d'harmoniser les différentes saisies sources en deux catégories normées, "HOMME" et "FEMME", garantissant ainsi la fiabilité des indicateurs de répartition par genre.

À l'instar de la dimension Train, ce flux utilise une gestion de type **SCD** pour maintenir l'intégrité du référentiel tout en suivant l'évolution des profils. Le job compare les données entrantes avec l'existant pour décider s'il doit effectuer une nouvelle insertion ou une mise à jour d'un client dont les informations (comme la ville ou le statut du compte) auraient changé




Le résultat dans le Data Warehouse présente une table nettoyée et segmentée, où chaque client est associé à des métadonnées de traçabilité, permettant de suivre précisément l'activité des voyageurs tout en évitant toute redondance d'information.

Result Grid | Filter Rows: | Edit: | Export/Import: | Wrap Cell Content: | Fetch rows:

| id_dim_client | id_client | nom_client | prenom_client | age | tranche_age | sexe | ville | pays | statut_compte | type_client | INSERT_DATE | UPDATE_DATE | PR_LIGNE_ACTIVE |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 1 | 1 | Martin | Chloe | 70 | Senior | FEMME | Lille | France | actif | particulier | 2026-04-17 16:09:05 | NULL | 1 |
| 2 | 2 | Thomas | Sophie | 34 | Jeune Adulte | FEMME | STRASBOURG | France | actif | particulier | 2026-04-17 16:09:05 | NULL | 1 |
| 3 | 3 | Richard | Camille | 36 | Adulte | FEMME | Bordeaux | France | suspendu | particulier | 2026-04-17 16:09:05 | NULL | 1 |
| 4 | 4 | Leroy | Louis | 70 | Senior | HOMME | nantes | France | actif | professionnel | 2026-04-17 16:09:05 | NULL | 1 |
| 5 | 5 | Dubois | Lucas | 21 | Jeune Adulte | HOMME | Lyon | Espagne | actif | professionnel | 2026-04-17 16:09:05 | NULL | 1 |
| 6 | 6 | Thomas | Julien | 68 | Senior | HOMME | Bordeaux | France | actif | particulier | 2026-04-17 16:09:05 | NULL | 1 |
| 7 | 7 | Dubois | Antoine | 71 | Senior | HOMME | Lyon | France | suspendu | particulier | 2026-04-17 16:09:05 | NULL | 1 |
| 8 | 8 | Richard | Emma | 60 | Adulte | FEMME | Marseille | Suisse | actif | particulier | 2026-04-17 16:09:05 | NULL | 1 |
| 9 | 9 | Thomas | Pierre | 52 | Adulte | HOMME | paris | France | actif | etudiant | 2026-04-17 16:09:05 | NULL | 1 |
| 10 | 10 | Thomas | Julie | 45 | Adulte | FEMME | toulouse | France | actif | particulier | 2026-04-17 16:09:05 | NULL | 1 |
| 11 | 11 | Bernard | Sophie | 53 | Adulte | FEMME | PARIS | France | actif | particulier | 2026-04-17 16:09:05 | NULL | 1 |
| 12 | 12 | Leroy | Pierre | 38 | Adulte | HOMME | Paris | France | actif | particulier | 2026-04-17 16:09:05 | NULL | 1 |

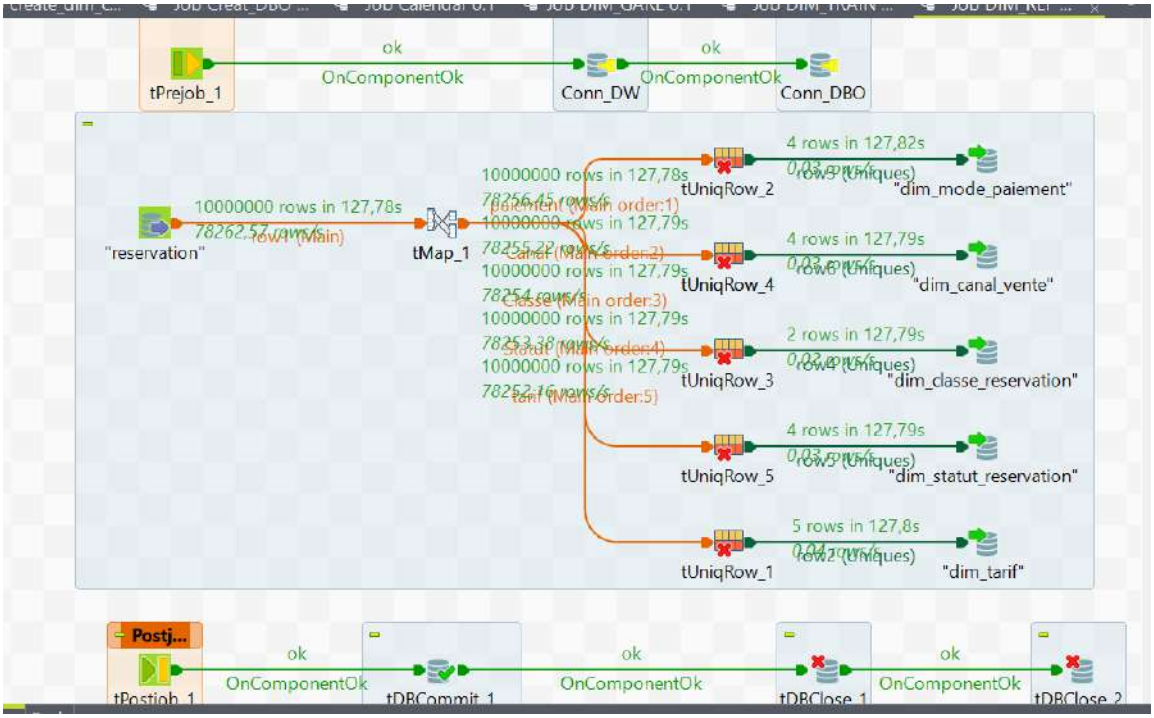
### *Junk Dimensions*

Dans notre schéma en étoile, nous avons fait le choix stratégique de créer des **Junk Dimensions** pour les attributs à faible cardinalité, tels que le **Mode de paiement**, le **Canal de vente** ou le **Type de tarif**. Par exemple, la dimension mode de paiement ne contient que quatre valeurs distinctes. Plutôt que de laisser ces informations sous forme de texte brut dans la table de faits, nous les avons isolées dans des tables de dimensions simplifiées.

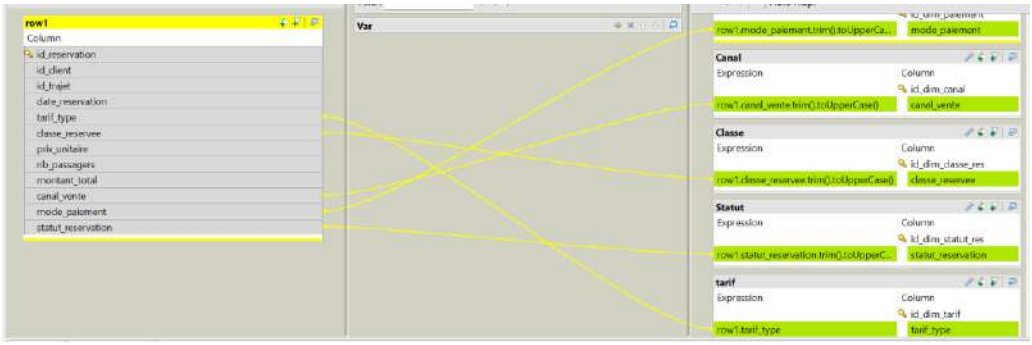
L'intérêt est double pour l'architecture du Data Warehouse :

- **Optimisation du stockage :** La table de faits ne stocke plus des chaînes de caractères répétitives comme "Carte Bancaire", mais uniquement un identifiant numérique (ID) très léger. Cela réduit considérablement la taille physique de la base de données.
- **Standardisation :** Cela garantit qu'il n'y a pas d'erreurs de saisie. En isolant ces modalités dans des tables de référence, on s'assure que chaque réservation pointe vers une valeur unique et normée, facilitant ainsi les calculs de répartition lors de la phase de visualisation.

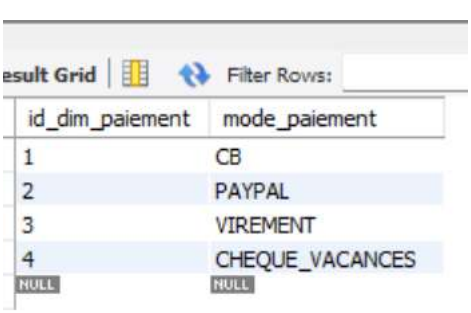
  La construction des dimensions de nomenclature, ou Junk Dimensions, repose sur un job Talend centralisé qui extrait les modalités uniques à partir des 10 millions de lignes de la table des réservations



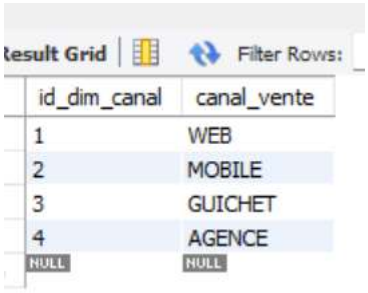

Pour chaque axe analytique (mode de paiement, canal de vente, classe de réservation, statut et type de tarif), nous utilisons un composant **tUniqRow** placé après le **tMap**. Ce processus est crucial : il permet de filtrer les données brutes pour ne conserver qu'une seule occurrence par modalité, créant ainsi des tables de référence épurées et sans doublons.



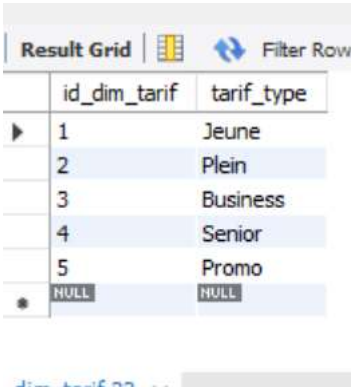
Cette approche transforme des colonnes de texte volumineuses en référentiels normés, où chaque libellé est associé à une clé technique auto-incrémentée unique.



| id_dim_paiement | mode_paiement |
|---|---|
| 1 | CB |
| 2 | PAYPAL |
| 3 | VIREMENT |
| 4 | CHEQUE_VACANCES |
| NULL | NULL |



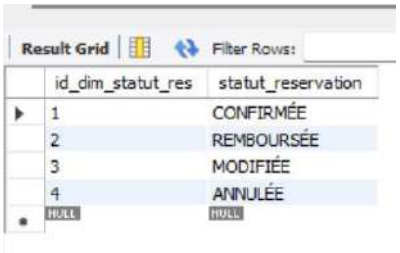
| id_dim_canal | canal_vente |
|---|---|
| 1 | WEB |
| 2 | MOBILE |
| 3 | GUICHET |
| 4 | AGENCE |
| NULL | NULL |



| id_dim_tarif | tarif_type |
|---|---|
| 1 | Jeune |
| 2 | Plein |
| 3 | Business |
| 4 | Senior |
| 5 | Promo |
| NULL | NULL |



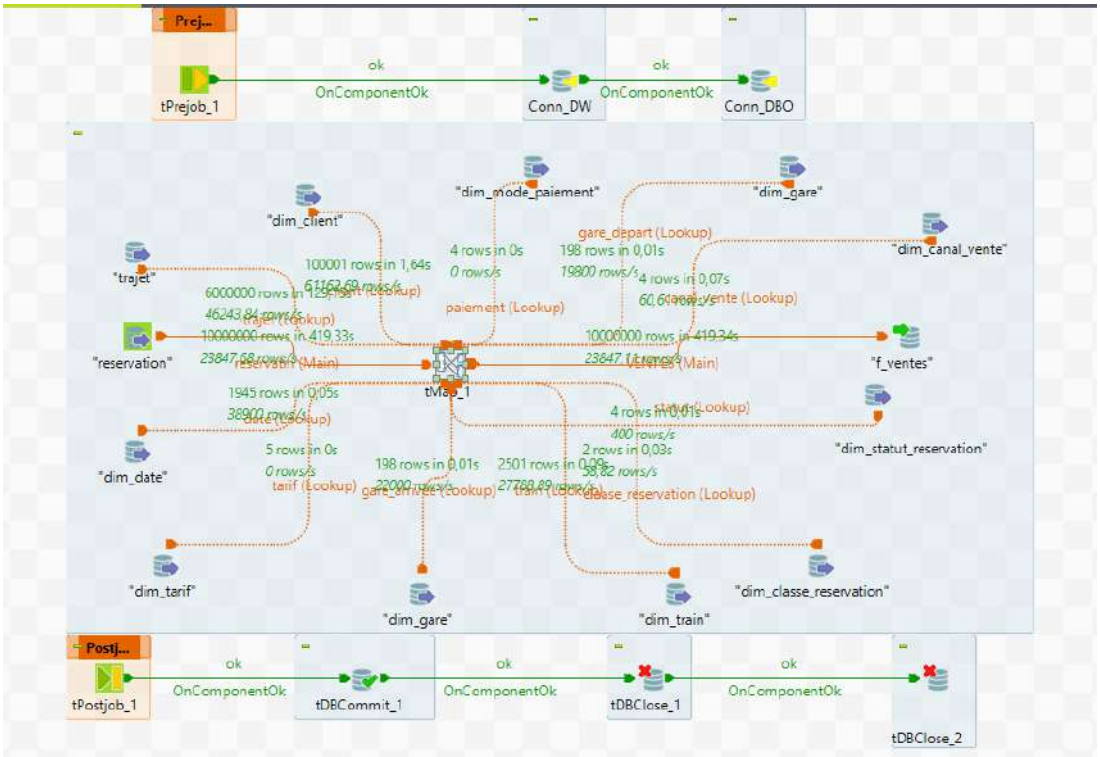
| id_dim_classe_res | classe_reservee |
|---|---|
| 1 | 1ÈRE |
| 2 | 2NDE |
| NULL | NULL |



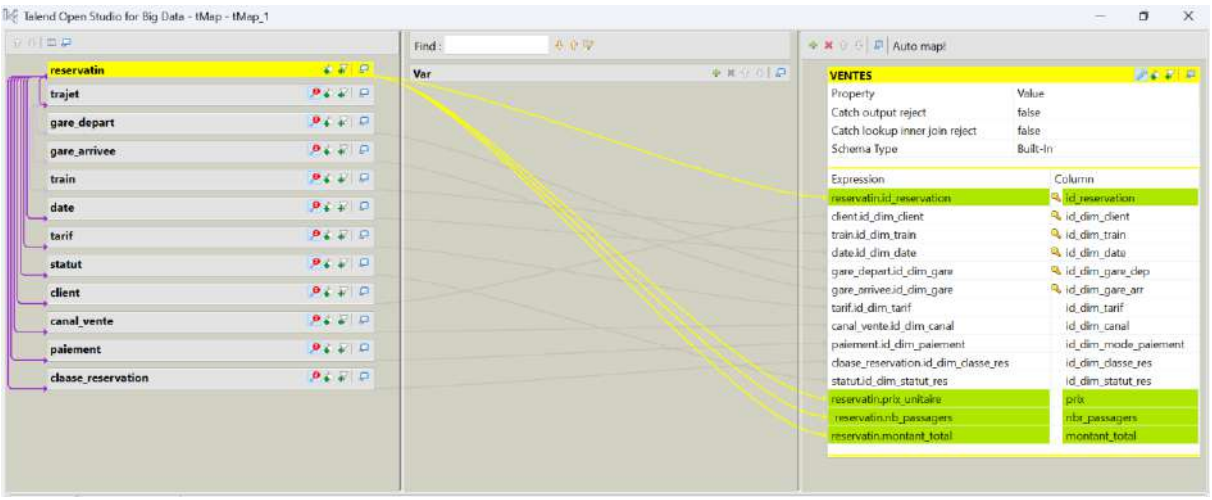
| id_dim_statut_res | statut_reservation |
|---|---|
| 1 | CONFIRMÉE |
| 2 | REMBOURSÉE |
| 3 | MODIFIÉE |
| 4 | ANNULÉE |
| NULL | NULL |

L'analyse des résultats dans le Data Warehouse confirme la pertinence de cette modélisation pour l'aide à la décision. On obtient des tables très légères mais stratégiques, comme dim_mode_paiement (regroupant les CB, Paypal, Virement et Chèque Vacances) ou dim_canal_vente (distinguant les ventes Web, Mobile, Guichet et Agence). En isolant ces attributs dans des dimensions dédiées, nous offrons une flexibilité totale pour croiser les données : il devient ainsi possible d'analyser instantanément quel canal de vente génère le plus de réservations "Confirmées" ou quel type de tarif est le plus utilisé selon le mode de paiement choisi.

*Table de fait (f_ventes)*



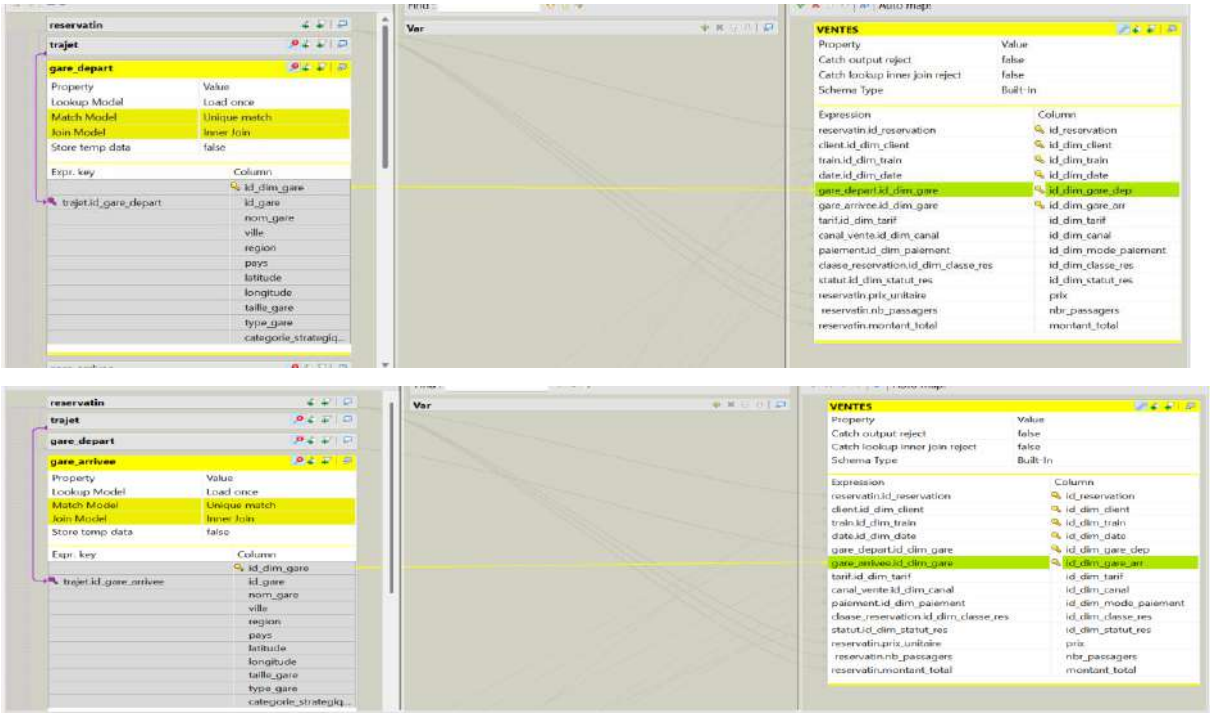

La table de faits constitue le point de convergence de l'ensemble du système décisionnel. Son alimentation via Talend repose sur une logique de jointures complexes réalisées dans le composant **tMap**, où les données transactionnelles de la DBO sont croisées avec toutes les dimensions précédemment chargées.




Pour garantir la précision des indicateurs, nous avons configuré les jointures dans le **tMap** en mode **Inner Join** associé au modèle **Unique match**. Ce choix technique est fondamental : il assure que seules les réservations possédant une correspondance exacte et unique dans chaque dimension sont intégrées. Si une donnée transactionnelle ne trouve pas son équivalent dans les

référentiels (comme un ID client inexistant), elle est automatiquement écartée, préservant ainsi le Data Warehouse de toute incohérence analytique.
job repose également sur l'utilisation stratégique des **Lookups**. Puisque la table de réservation source ne contient pas directement toutes les informations de voyage, nous effectuons une jointure intermédiaire sur la table **trajet**. Cette étape est indispensable pour récupérer les identifiants de la **gare de départ** et de la **gare d'arrivée**, permettant ainsi de réaliser la double jointure sur dim_gare. En consolidant l'ensemble de ces liens (Client, Train, Date, Tarifs), la table de faits devient un réceptacle optimisé ne contenant que des clés techniques numériques et des mesures calculées.

L'objectif est de transformer les identifiants métier en **clés techniques** uniques tout en isolant les **mesures** quantitatives, telles que le montant total, le prix unitaire et Nbr de passagers . Une particularité majeure de notre modèle réside dans la gestion de la dimension géographique : la table dim_gare y joue un double rôle (Role-Playing Dimension), intervenant via deux jointures distinctes pour identifier avec précision la **gare de départ** et la **gare d'arrivée** pour chaque trajet.




Une fois le job exécuté, la table de faits devient une mine d'informations structurée et légère. Bien que ce socle soit destiné à alimenter des outils de BI comme Power BI, il permet déjà d'effectuer des analyses directes et rapides via des requêtes SQL simples sur MySQL.

Nous pouvons instantanément calculer des indicateurs stratégiques tels que le **Chiffre d'Affaires total**

```
1 •  select SUM(montant_total) AS CA_total
2    From f_ventes;
```

Result Grid | Filter Rows: | Export: | Wrap

| CA_total |
|---|
| 1803969162.08 |

Ou la répartition des ventes par **canal de vente**. Ces premières requêtes confirment la cohérence du Data Warehouse.

```
3 •  SELECT COUNT(*) FROM f_ventes;SELECT d.canal_vente, SUM(f.montant_total) as Total
4    FROM f_ventes f
5    JOIN dim_canal_vente d ON f.id_dim_canal = d.id_dim_canal
6    GROUP BY d.canal_vente
7 •  ORDER BY d.canal_vente;SELECT d.canal_vente, SUM(f.montant_total) as Total
8
```

Result Grid | Filter Rows: | Export: | Wrap Cell Content:

| canal_vente | Total |
|---|---|
| AGENCE | 90368406.07 |
| GUICHET | 270647695.46 |
| MOBILE | 451173190.35 |
| WEB | 991779870.20 |

la table de faits ne contient plus de texte redondant, mais uniquement des chiffres et des clés techniques, garantissant ainsi une performance de calcul optimale pour le pilotage de l'activité ferroviaire.

| id_reser | id_dim_ | id_dim_tr | id_dim_date | id_dim | id_dir | id_c | id_ | id_dim | id_dim_clas | id_dim_statut_res | prix | nbr_pass | montant_ |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 1 | 33363 | 1692 | 20210428 | 1 | 119 | 1 | 1 | 1 | 1 | 1 | 46.57 | 4 | 186.28 |
| 2 | 41386 | 898 | 20210516 | 93 | 129 | 2 | 1 | 1 | 2 | 1 | 141.73 | 1 | 141.73 |
| 3 | 69566 | 1415 | 20201013 | 167 | 16 | 2 | 1 | 1 | 1 | 1 | 109.21 | 4 | 436.84 |
| 4 | 84040 | 609 | 20210904 | 131 | 72 | 3 | 1 | 2 | 1 | 1 | 16.51 | 3 | 49.53 |
| 5 | 97092 | 1275 | 20210518 | 61 | 35 | 2 | 1 | 1 | 2 | 2 | 122.84 | 4 | 491.36 |
| 6 | 24777 | 578 | 20210116 | 152 | 195 | 3 | 2 | 1 | 2 | 1 | 12.68 | 4 | 50.72 |
| 7 | 92631 | 1798 | 20210918 | 48 | 15 | 2 | 1 | 1 | 2 | 2 | 73.91 | 2 | 147.82 |
| 8 | 15280 | 1392 | 20210317 | 146 | 50 | 4 | 1 | 1 | 2 | 3 | 102.92 | 4 | 411.68 |
| 9 | 91190 | 73 | 20210612 | 12 | 33 | 2 | 2 | 1 | 2 | 1 | 46.75 | 2 | 93.50 |
| 10 | 44584 | 1328 | 20210223 | 55 | 165 | 5 | 2 | 1 | 2 | 1 | 87.40 | 1 | 87.40 |
| 11 | 37062 | 1644 | 20210512 | 196 | 132 | 4 | 1 | 1 | 2 | 1 | 45.51 | 4 | 182.04 |
| 12 | 31968 | 640 | 20210716 | 182 | 117 | 2 | 2 | 1 | 2 | 1 | 106.12 | 1 | 106.12 |
| 13 | 92912 | 2383 | 20210201 | 168 | 120 | 5 | 1 | 1 | 2 | 1 | 71.01 | 1 | 71.01 |
| 14 | 25700 | 1980 | 20210108 | 97 | 48 | 5 | 1 | 2 | 2 | 2 | 36.92 | 2 | 73.84 |
| 15 | 7663 | 2169 | 20210906 | 167 | 27 | 3 | 3 | 1 | 1 | 1 | 90.80 | 3 | 272.40 |
| 16 | 70347 | 1778 | 20201116 | 14 | 65 | 3 | 3 | 1 | 2 | 1 | 63.67 | 4 | 254.68 |

En conclusion, ce chapitre a permis de transformer une base de données opérationnelle brute en un **Data Warehouse** cohérent, robuste et entièrement optimisé pour l'aide à la décision. Grâce à l'application rigoureuse du **schéma en étoile**, nous disposons désormais d'une structure où chaque dimension (Client, Train, Temps, etc.) sert d'axe d'analyse précis autour d'une table de faits centrale dédiée aux ventes. L'intégration de concepts avancés, tels que les **Junk Dimensions** pour la gestion des nomenclatures et les **Role-playing Dimensions** pour le double rôle des gares, garantit une flexibilité totale lors de l'exploration des données.

Fort de cette architecture stable, deux voies s'ouvrent désormais pour l'exploitation des résultats. Nous pouvons choisir de connecter directement notre entrepôt à **Power BI** pour une visualisation rapide via le langage DAX, ou passer par une étape intermédiaire sous **SQL Server Management Studio (SSMS)**. Cette seconde option permettrait la création de vues spécialisées et le développement d'un **cube OLAP** via SSAS, offrant ainsi la puissance du langage **MDX** pour des analyses multidimensionnelles encore plus complexes avant la restitution finale.

# Chapitre 5 : Migration et Analyse Multidimensionnelle avec SSAS

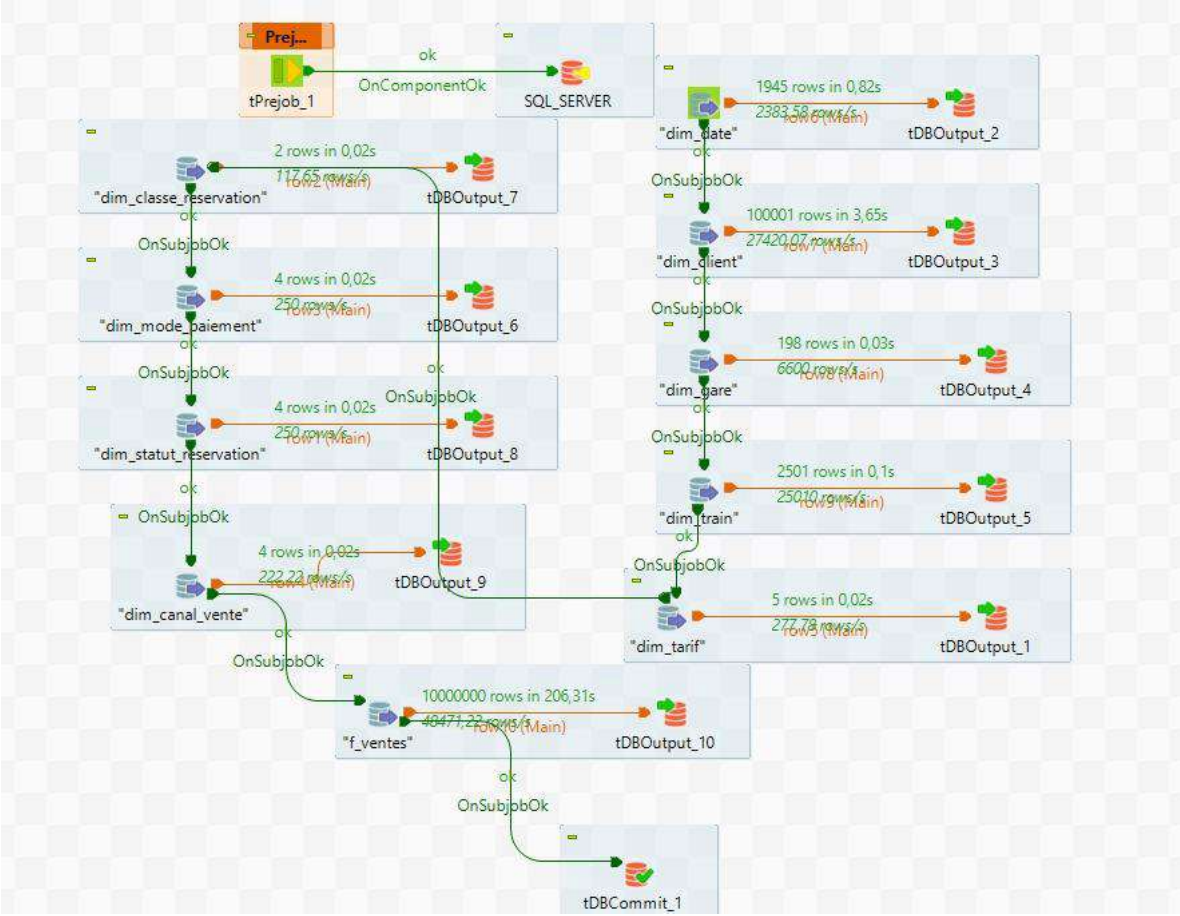
L'objectif de ce chapitre est de passer d'un modèle de données passif à un modèle multidimensionnel actif. En migrant nos données vers SQL Server et en utilisant SQL Server Analysis Services (SSAS), nous allons construire un Cube OLAP. Cette structure permettra non seulement de pré-calculer des agrégations sur des millions de lignes, mais aussi d'utiliser la puissance du langage MDX pour effectuer des analyses croisées difficiles à réaliser avec du SQL classique.

## 1. Migration des données de MySQL vers SQL Server

Il est important de souligner qu'il existe plusieurs approches techniques pour migrer un Data Warehouse d'un environnement open-source comme MySQL vers l'écosystème propriétaire de Microsoft. On peut notamment citer l'utilisation de scripts SQL d'export/import (fichiers .sql), l'emploi de connecteurs ODBC/OLEDB pour des transferts directs, ou encore l'usage d'outils spécialisés comme SSMA (SQL Server Migration Assistant), conçu pour automatiser la conversion des schémas. Chacune de ces méthodes présente des avantages en termes de rapidité, mais elles manquent souvent de flexibilité lorsqu'il s'agit de manipuler les données ou de surveiller précisément les flux durant la transition.

Dans le cadre de ce projet, nous avons choisi d'utiliser **Talend** pour orchestrer cette migration. Ce choix stratégique permet de démontrer la puissance et la polyvalence de cet outil ETL, capable de gérer de manière transparente des sources et des cibles hétérogènes. En utilisant Talend, nous ne nous contentons pas de copier des tables ; nous pilotons un flux intelligent qui garantit la correspondance parfaite des types de données entre MySQL et SQL Server, tout en offrant une visibilité totale sur les volumes transférés et une gestion fine des erreurs, confirmant ainsi que Talend est un pivot central capable de s'adapter à n'importe quel environnement technique de sortie.

Le job Talend de migration a été conçu pour reproduire l'intégralité du Data Warehouse avec une précision . Comme illustré dans le flux ci-dessous , nous utilisons une série de composants tDBInput (MySQL) reliés à des tDBOutput (SQL Server). L'utilisation systématique des liens OnSubjobOK permet de séquencer le transfert : nous migrons d'abord les dimensions de référence et les Junk Dimensions, puis nous terminons par la table de faits f_ventes. Ce séquençage est indispensable pour préparer l'environnement SQL Server à recevoir les données transactionnelles tout en garantissant que les référentiels sont déjà présents et complets.




Une fois le transfert des données finalisé, une étape fondamentale consiste à exécuter des requêtes SQL pour la **recréation des clés étrangères** directement sur SQL Server pour :

- **Sécurité et Cohérence :** Les clés étrangères verrouillent l'intégrité physique du schéma en étoile. Elles garantissent qu'aucune vente ne peut exister sans un client, un train ou une date valide, empêchant ainsi toute corruption accidentelle des données après la migration.
- **Optimisation du Cube SSAS :** L'outil **SQL Server Analysis Services (SSAS)** s'appuie sur ces contraintes physiques pour détecter automatiquement les relations lors de la

création de la vue de source de données. Sans ces clés, le moteur décisionnel ne pourrait pas lier intelligemment les faits aux dimensions.

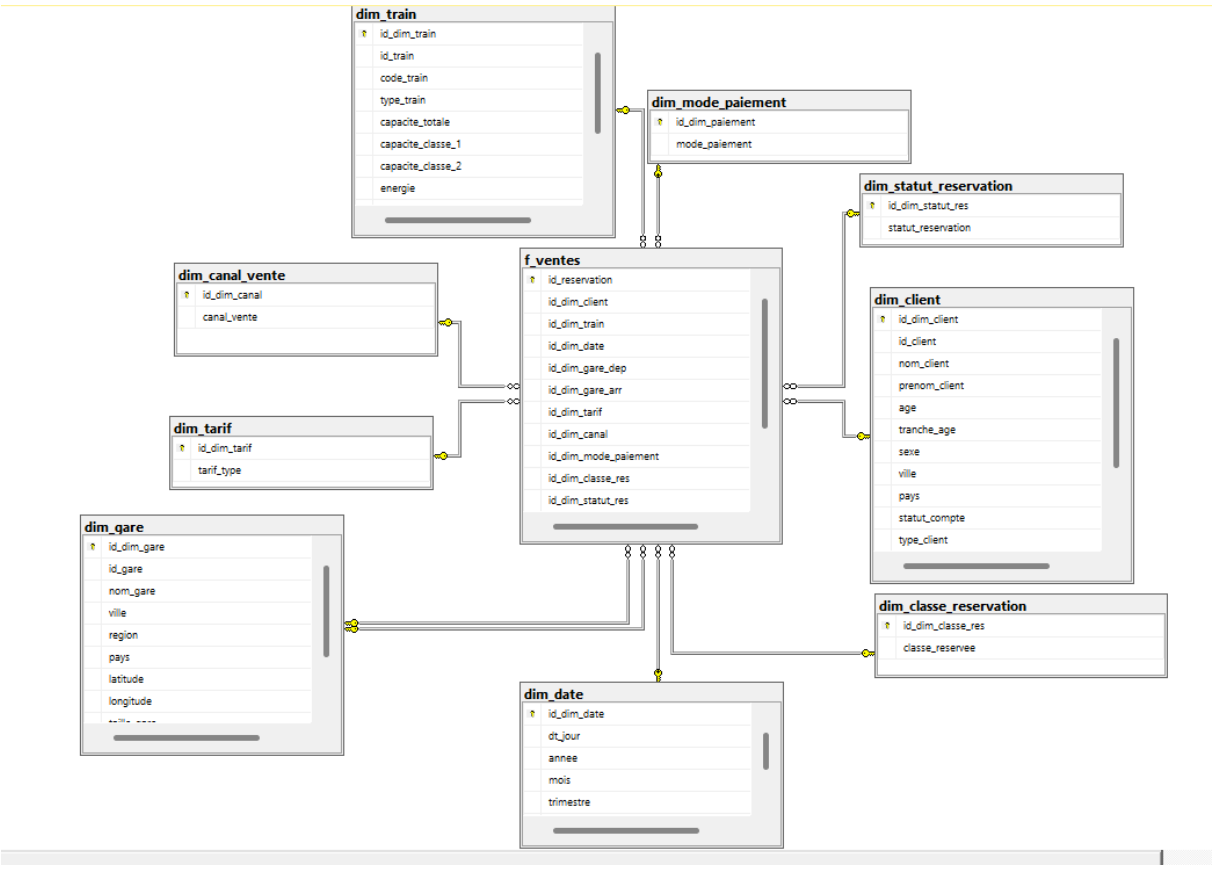
- **Performance des requêtes :** SQL Server utilise les index des clés étrangères pour optimiser les plans d'exécution des requêtes multidimensionnelles, ce qui accélère considérablement le temps de réponse lors de l'analyse des millions de lignes de réservations.

```
s_Client FOREIGN KEY (id_dim_client) REFERENCES dim_client(id_dim_client);
s_Train FOREIGN KEY (id_dim_train) REFERENCES dim_train(id_dim_train);
s_Date FOREIGN KEY (id_dim_date) REFERENCES dim_date(id_dim_date);


s_GareDep FOREIGN KEY (id_dim_gare_dep) REFERENCES dim_gare(id_dim_gare);
s_GareArr FOREIGN KEY (id_dim_gare_arr) REFERENCES dim_gare(id_dim_gare);


s_Tarif FOREIGN KEY (id_dim_tarif) REFERENCES dim_tarif(id_dim_tarif);
s_Canal FOREIGN KEY (id_dim_canal) REFERENCES dim_canal_vente(id_dim_canal);
s_Paiement FOREIGN KEY (id_dim_mode_paiement) REFERENCES dim_mode_paiement(id_dim_paiement);
s_Classe FOREIGN KEY (id_dim_classe_res) REFERENCES dim_classe_reservation(id_dim_classe_res);
s_Statut FOREIGN KEY (id_dim_statut_res) REFERENCES dim_statut_reservation(id_dim_statut_res);
```

Une fois l'intégralité des données chargée et les contraintes d'intégrité physique rétablies, nous procédons à une phase de validation critique sous SQL Server Management Studio (SSMS). Cette étape commence par la vérification visuelle de notre schéma en étoile : grâce à l'outil de diagramme de base de données, nous confirmons que la table de faits f_ventes est correctement liée à toutes ses dimensions (Client, Date, Train, Gares, etc.) via les clés étrangères précédemment recréées. Cette structure centralisée garantit que le moteur SQL peut naviguer efficacement entre les axes d'analyse et les mesures chiffrées, validant ainsi la cohérence architecturale de notre entrepôt de données avant son exploitation multidimensionnelle.




Pour certifier la fiabilité du transfert, nous exécutons ensuite une série de requêtes SQL analytiques permettant de confronter les résultats obtenus avec ceux de la source. Cette vérification s'appuie sur trois axes principaux :

SQLQuery2.sql - (l...FI4DCP8\Salma (56))*

```sql
SELECT
    t.name AS TableName,
    p.rows AS RowCounts
FROM
    sys.tables AS t
INNER JOIN
    sys.partitions AS p ON t.object_id = p.object_id
WHERE
    p.index_id IN (0,1) -- 0: Heap, 1: Clustered Index
ORDER BY
    p.rows DESC;
```

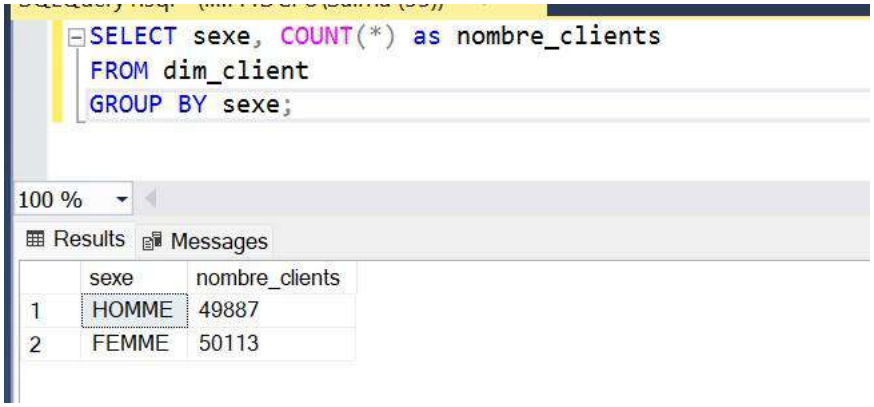
100 %

Results | Messages

| | TableName | RowCounts |
|---|---|---|
| 1 | f_ventes | 10000000 |
| 2 | dim_client | 100001 |
| 3 | dim_train | 2501 |
| 4 | dim_date | 1945 |
| 5 | dim_gare | 198 |
| 6 | dim_tarif | 5 |
| 7 | dim_mode_paiement | 4 |
| 8 | dim_statut_reservation | 4 |
| 9 | dim_canal_vente | 4 |
| 10 | dim_classe_reservation | 2 |

Nous effectuons un décompte pour chaque table afin de nous assurer qu'aucune ligne n'a été perdue durant la migration, confirmant la présence exacte de nos 10 millions de réservations.

- l'analyse du nombre d'hommes par rapport aux femmes



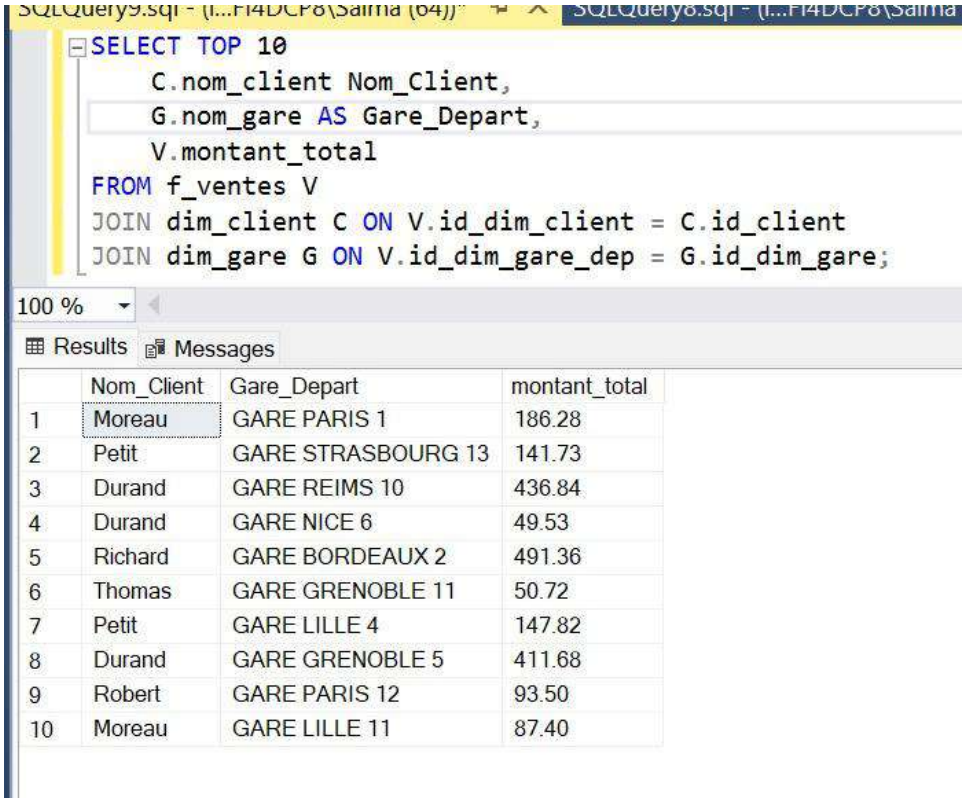
```
SELECT sexe, COUNT(*) as nombre_clients
FROM dim_client
GROUP BY sexe;
```

100 %

Results | Messages

| | sexe | nombre_clients |
|---|---|---|
| 1 | HOMME | 49887 |
| 2 | FEMME | 50113 |

- l'identification du **Top 10 des clients** par chiffre d'affaires, démontre la capacité du nouveau serveur à traiter rapidement des agrégations massives :



```
SELECT TOP 10
    C.nom_client Nom_Client,
    G.nom_gare AS Gare_Depart,
    V.montant_total
FROM f_ventes V
JOIN dim_client C ON V.id_dim_client = C.id_client
JOIN dim_gare G ON V.id_dim_gare_dep = G.id_dim_gare;
```

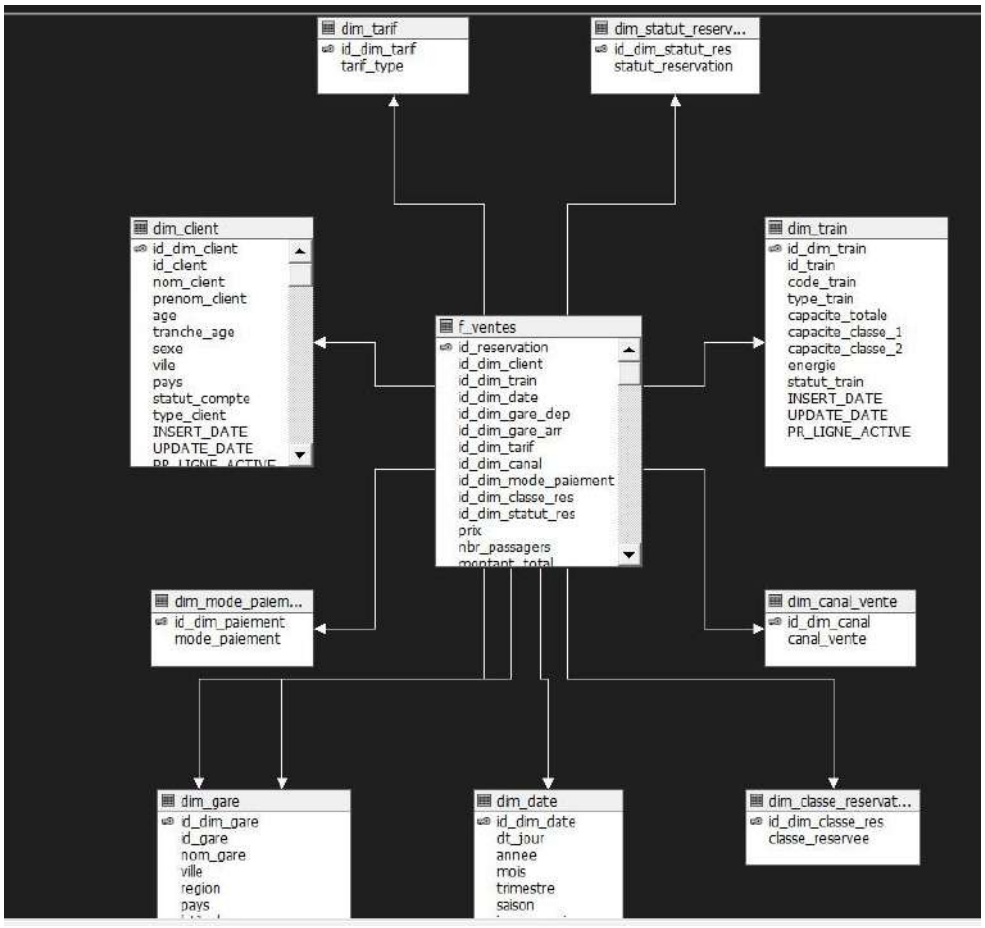
100 %

Results | Messages

| | Nom_Client | Gare_Depart | montant_total |
|---|---|---|---|
| 1 | Moreau | GARE PARIS 1 | 186.28 |
| 2 | Petit | GARE STRASBOURG 13 | 141.73 |
| 3 | Durand | GARE REIMS 10 | 436.84 |
| 4 | Durand | GARE NICE 6 | 49.53 |
| 5 | Richard | GARE BORDEAUX 2 | 491.36 |
| 6 | Thomas | GARE GRENOBLE 11 | 50.72 |
| 7 | Petit | GARE LILLE 4 | 147.82 |
| 8 | Durand | GARE GRENOBLE 5 | 411.68 |
| 9 | Robert | GARE PARIS 12 | 93.50 |
| 10 | Moreau | GARE LILLE 11 | 87.40 |

# 2. Création de la vue de source de données et construction du Cube

La création du cube analytique constitue le cœur du processus SSAS. Cette phase débute par la définition d'une Data Source View (DSV), qui agit comme une couche d'abstraction entre la base SQL Server et le modèle décisionnel. En important nos tables de faits et de dimensions dans cet espace de travail, Visual Studio détecte automatiquement les relations grâce aux clés étrangères précédemment recréées. Comme on peut le voir sur le diagramme de la DSV, la table de faits f_ventes est au centre de l'architecture, entourée de ses dimensions, confirmant ainsi la structure en étoile parfaitement migrée.




La simple importation des tables ne suffit pas à créer un modèle performant ; il est nécessaire de configurer chaque dimension pour faciliter la navigation dans les données. Pour les dimensions majeures, nous avons mis en place des **hiérarchies**, une structure logique qui permet aux utilisateurs de passer d'une vue d'ensemble à un détail granulaire (principe du Drill-Down).

- **Dimension Date :** Une hiérarchie temporelle classique a été établie, structurant les données de l'**Année** vers le **Trimestre**, puis le **Mois** jusqu'au **Jour** (Dt Jour). Cela permet d'analyser l'évolution du chiffre d'affaires par saisonnalité.

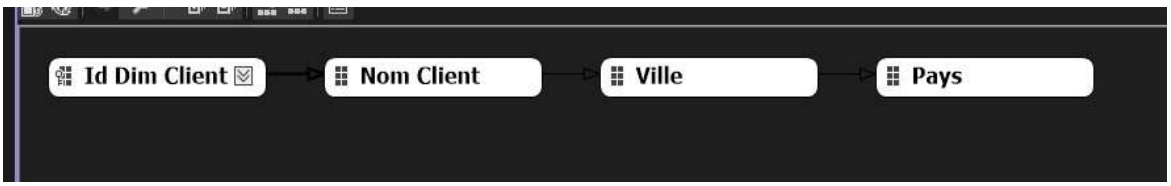




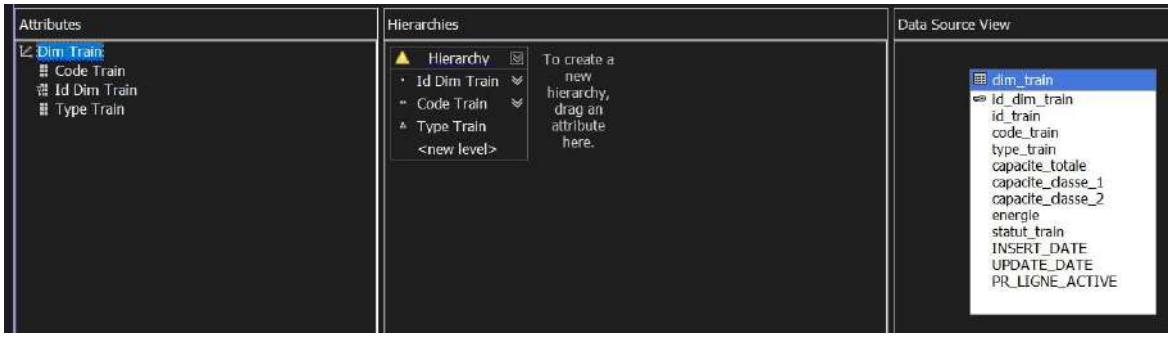


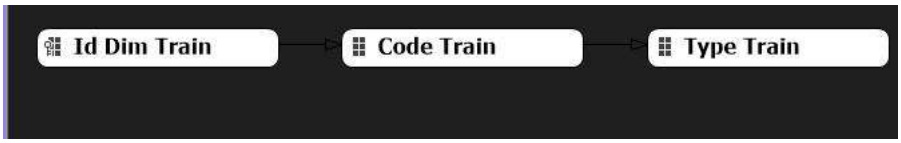
- **Dimension Client :** Nous avons créé une hiérarchie géographique et sociale permettant de regrouper les clients par **Pays**, puis par **Ville**, jusqu'au **Nom du client**.



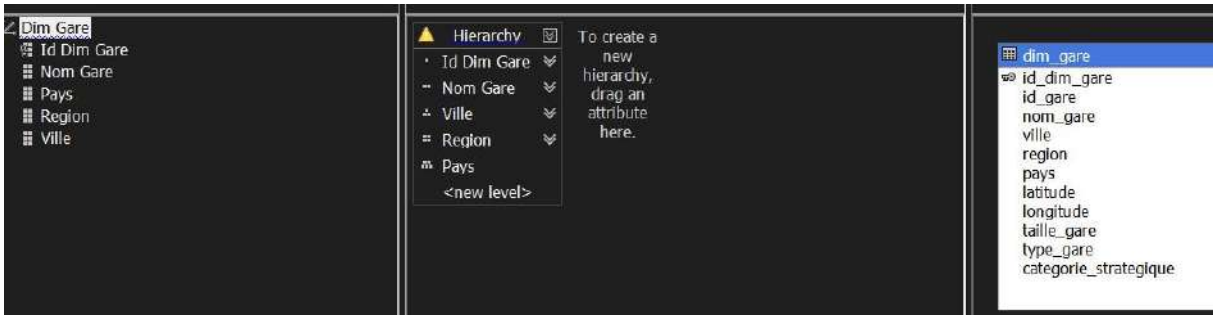




- **Dimension Train :** La structure permet ici de segmenter le parc roulant par **Type de train** puis par **Code Train** spécifique.






- **Dimension Gare :** Une hiérarchie allant du **Pays** et de la **Region** vers la **Ville** et enfin le **Nom de la Gare**.

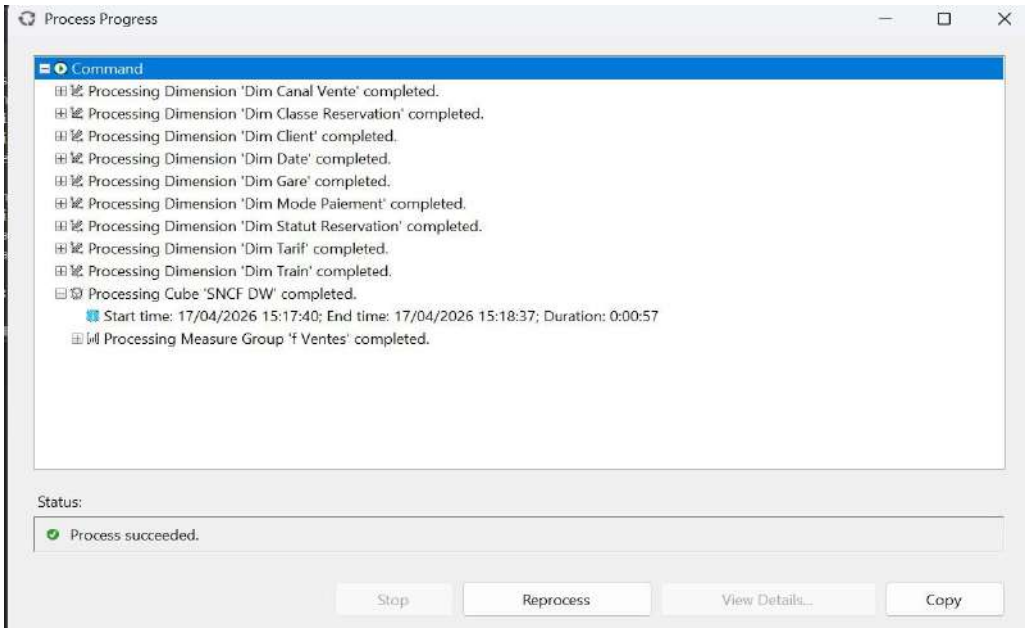






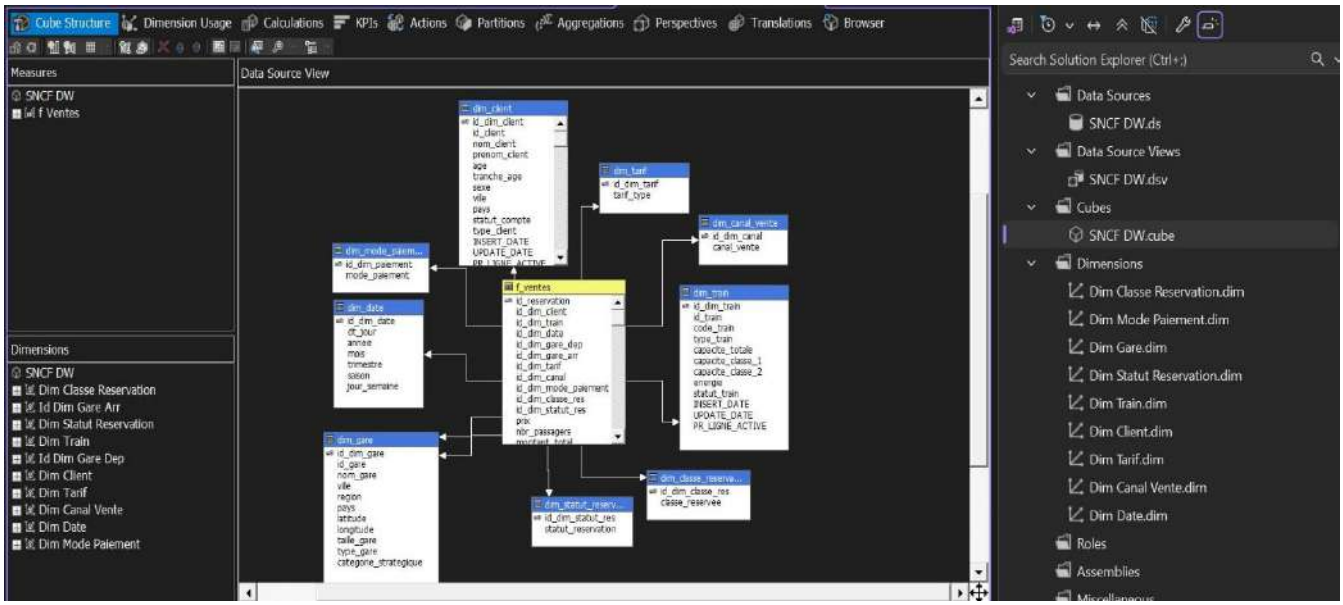
Il est important de noter que si ces dimensions principales bénéficient de hiérarchies pour la navigation, les autres dimensions du projet (les **Junk Dimensions** comme le Mode de paiement, le Statut ou le Tarif) sont également présentes et opérationnelles dans le modèle. Bien qu'elles ne possèdent pas de structures hiérarchiques complexes en raison de leur faible nombre de modalités, elles constituent des axes de filtrage essentiels qui viennent enrichir les possibilités de croisement lors de l'analyse multidimensionnelle. L'ensemble de ces dimensions ainsi paramétrées forme l'ossature sur laquelle repose désormais la structure globale de notre Cube.

Une fois la phase de conception finalisée sous Visual Studio, le cube doit être physiquement généré sur le serveur **SQL Server Analysis Services**. Cette étape de mise en production se décompose en deux opérations majeures : le **Déploiement**, qui transfère la structure logique vers le serveur, et le **Traitement (Process)**, qui alimente cette structure en calculant les agrégations sur les millions de lignes de données.




Le cube est désormais parfaitement structuré et visible dans l'explorateur de solutions de Visual Studio.

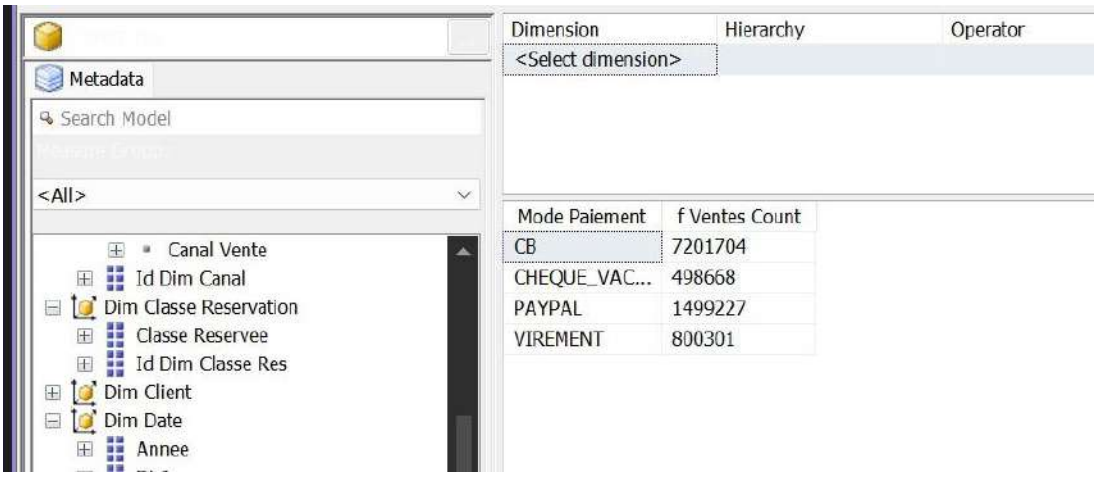
Cette vue d'ensemble confirme que toutes les dimensions, les hiérarchies et les mesures de ventes sont correctement imbriquées au sein d'une seule unité logique. À ce stade, le cube n'est plus une simple maquette de conception, mais un moteur de calcul haute performance prêt à répondre instantanément aux analyses multidimensionnelles les plus complexes.



# 3. Analyse avancée en langage MDX

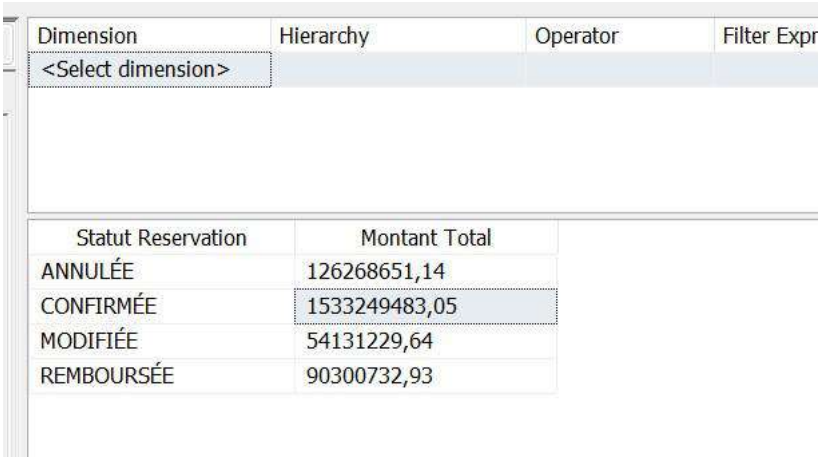
Le cube étant désormais déployé et traité, nous quittons le monde du SQL relationnel pour exploiter la puissance du langage **MDX .**Cette phase permet d'interroger les cellules du cube pour extraire des indicateurs complexes et croiser les dimensions de manière agile. L'interface "Browser" de Visual Studio nous permet de simuler ces requêtes et de valider les comportements analytiques.

- La fréquence d'utilisation de chaque service de paiement.




On remarque domination de la **Carte Bancaire (CB)** avec plus de 7 millions de transactions montre qu'il s'agit du canal critique pour la stabilité du système. À l'inverse, le volume plus faible des **Chèques Vacances** ou des **Virements** .

- Analyse du Chiffre d'Affaires par Statut de Réservation



Cette requête MDX permet d'isoler la valeur financière réelle de l'activité. En segmentant le Montant Total par statut, on distingue immédiatement la part du chiffre d'affaires sécurisée de celle qui représente un manque à gagner ou un flux de gestion (ANNULÉE, REMBOURSÉE).

- Segmentation Marketing (Tranche d'âge et Type de Client)

| Tranche Age | Type Client | Nbr Passagers |
|---|---|---|
| Adulte | etudiant | 1907957 |
| Adulte | particulier | 7716836 |
| Adulte | professionnel | 3261121 |
| Jeune Adulte | etudiant | 1110596 |
| Jeune Adulte | particulier | 4438275 |
| Jeune Adulte | professionnel | 1842109 |
| Senior | etudiant | 713875 |
| Senior | particulier | 2852335 |
| Senior | professionnel | 1159261 |

Cette analyse répartit le Nombre de Passagers selon leur profil social et leur âge.
Observation : Le segment des "Adultes Particuliers" est le moteur principal du trafic (plus de 7,7 millions de passagers).
Cette vue permet de vérifier si la stratégie commerciale est efficace. Si le volume de "Seniors" est faible sur certains trajets, le marketing peut décider de lancer une offre promotionnelle ciblée. Le cube permet de passer instantanément d'une vision globale à une vision granulaire, facilitant la création de campagnes de fidélisation ultra-personnalisées.

- Analyse du Comportement de Paiement selon le Statut de réservation

| Statut Reservation | Mode Paiement | Montant Total |
|---|---|---|
| ANNULÉE | CB | 90723515,68 |
| ANNULÉE | CHEQUE_VACANCES | 6375771,95 |
| ANNULÉE | PAYPAL | 19021590 |
| ANNULÉE | VIREMENT | 10147773,51 |
| CONFIRMÉE | CB | 1104401176,44 |
| CONFIRMÉE | CHEQUE_VACANCES | 76367207,65 |
| CONFIRMÉE | PAYPAL | 229883607,12 |
| CONFIRMÉE | VIREMENT | 122597491,84 |
| MODIFIÉE | CB | 39079084,2 |
| MODIFIÉE | CHEQUE_VACANCES | 2681576,89 |
| MODIFIÉE | PAYPAL | 8023437,85 |
| MODIFIÉE | VIREMENT | 4347130,7 |
| REMBOURSÉE | CB | 65111454,29 |
| REMBOURSÉE | CHEQUE_VACANCES | 4575019,91 |
| REMBOURSÉE | PAYPAL | 13418771,82 |
| REMBOURSÉE | VIREMENT | 7195486,91 |

En croisant le **Statut de Réservation** avec le **Mode de Paiement**, nous mettons en lumière la fiabilité des flux financiers.

On constate que la Carte Bancaire génère le plus gros montant de réservations "Confirmées" (plus de 110 millions), mais elle est aussi en tête des montants "Annulés".

Cela suggère une corrélation entre la facilité d'utilisation du paiement en ligne et la volatilité des réservations. À l'inverse, les paiements par **Virement** ou **Chèques Vacances** présentent des montants plus stables, souvent liés à une planification de voyage plus rigoureuse.
Cette analyse permet à la SNCF d'ajuster ses politiques de frais d'annulation selon le mode de paiement utilisé.

- Analyse des Flux entrants par Gare d'Arrivée

  La capacité de filtrer une dimension spécifique pour observer son impact sur le reste du modèle : la capacité de filtrer une dimension spécifique pour observer son impact sur le reste du modèle

| Dimension | Hierarchy | Operator | Filter Expression | Param |
|---|---|---|---|---|
| Id Dim Gare Arr | Id Dim Gare Arr.Hi... | Equal | { GARE PARIS 2 } | |
| <Select dimension> | | | | |

| Id Dim Gare | Nom Gare | Ville | Region | Pays | Nbr Passagers |
|---|---|---|---|---|---|
| 1 | GARE PARIS 1 | PARIS | ÎLE-DE-FRANCE | FRANCE | 563 |
| 3 | GARE PARIS 3 | PARIS | ÎLE-DE-FRANCE | FRANCE | 663 |
| 4 | GARE PARIS 4 | PARIS | ÎLE-DE-FRANCE | FRANCE | 602 |
| 5 | GARE PARIS 5 | PARIS | ÎLE-DE-FRANCE | FRANCE | 547 |
| 6 | GARE PARIS 6 | PARIS | ÎLE-DE-FRANCE | FRANCE | 706 |
| 7 | GARE PARIS 7 | PARIS | ÎLE-DE-FRANCE | FRANCE | 745 |
| 8 | GARE PARIS 8 | PARIS | ÎLE-DE-FRANCE | FRANCE | 579 |
| 9 | GARE PARIS 9 | PARIS | ÎLE-DE-FRANCE | FRANCE | 652 |
| 10 | GARE PARIS 10 | PARIS | ÎLE-DE-FRANCE | FRANCE | 633 |
| 11 | GARE PARIS 11 | PARIS | ÎLE-DE-FRANCE | FRANCE | 710 |
| 12 | GARE PARIS 12 | PARIS | ÎLE-DE-FRANCE | FRANCE | 611 |
| 13 | GARE LYON 1 | LYON | AUVERGNE-RHÔNE-A... | FRANCE | 604 |
| 14 | GARE LYON 2 | LYON | AUVERGNE-RHÔNE-A... | FRANCE | 644 |
| 15 | GARE LYON 3 | LYON | AUVERGNE-RHÔNE-A... | FRANCE | 764 |
| 16 | GARE LYON 4 | LYON | AUVERGNE-RHÔNE-A... | FRANCE | 580 |
| 17 | GARE LYON 5 | LYON | AUVERGNE-RHÔNE-A... | FRANCE | 697 |
| 18 | GARE LYON 6 | LYON | AUVERGNE-RHÔNE-A... | FRANCE | 610 |
| 19 | GARE LYON 7 | LYON | AUVERGNE-RHÔNE-A... | FRANCE | 636 |

Le tableau affiche le nombre de passagers en provenance de diverses autres gares (Gare Paris 1, Gare Lyon 1….) ayant pour destination finale la gare GARE PARIS 2.

Ce chapitre a marqué une étape décisive dans la transformation de notre système décisionnel, passant d'un stockage relationnel classique à une structure multidimensionnelle de haute performance.

Le processus de création et de déploiement du cube a suivi une rigueur méthodologique indispensable : de la **migration des données via Talend** à la définition d'une **Data Source View (DSV)** cohérente, jusqu'à la configuration minutieuse des mesures et des dimensions. Le succès du **déploiement et du traitement (Process)** sur SQL Server Analysis Services confirme la robustesse de notre architecture, désormais capable de gérer et d'agréger plus de 10 millions de lignes de données ferroviaires de manière quasi instantanée.

L'un des apports majeurs de ce chapitre réside dans la mise en place des **hiérarchies**. Ces structures sont des véritables leviers d'exploration. Elles permettent de naviguer avec agilité dans la **granularité** des données grâce au **Drill-down**. Un utilisateur peut ainsi partir d'une vision globale (Chiffre d'affaires annuel ou par Pays) et descendre en un clic vers un détail extrêmement fin (ex: CA par jour ou par gare spécifique), offrant une profondeur d'analyse indispensable pour identifier les tendances locales ou les pics de saisonnalité.

Enfin, l'utilisation du langage **MDX** a révélé la supériorité du modèle multidimensionnel pour le pilotage stratégique. Là où une requête SQL complexe nécessiterait des jointures coûteuses et un temps d'exécution long pour scanner des millions de lignes, le cube SSAS répond en quelques millisecondes. La force de cette solution réside dans sa capacité à croiser instantanément plusieurs perspectives par simple glisser-déposer.

Forts de cette compréhension approfondie de nos indicateurs et de la validation de notre modèle de données sous SQL Server, nous pouvons désormais entamer la phase finale de **Visualisation et de Reporting sous Power BI** pour concevoir des tableaux de bord interactifs et dynamiques.

# Chapitre 6 : Business Intelligence et Data visualisation sous Power BI

L'aboutissement de notre projet décisionnel repose sur la capacité à traduire une infrastructure de données robuste en un outil de pilotage stratégique. Après avoir exploré la puissance du calcul multidimensionnel via la création de cubes sous **SSAS (SQL Server Analysis Services)** et l'exécution de requêtes complexes en langage **MDX**, nous avons fait le choix stratégique de connecter **Power BI** directement à notre **Data Warehouse MySQL**.

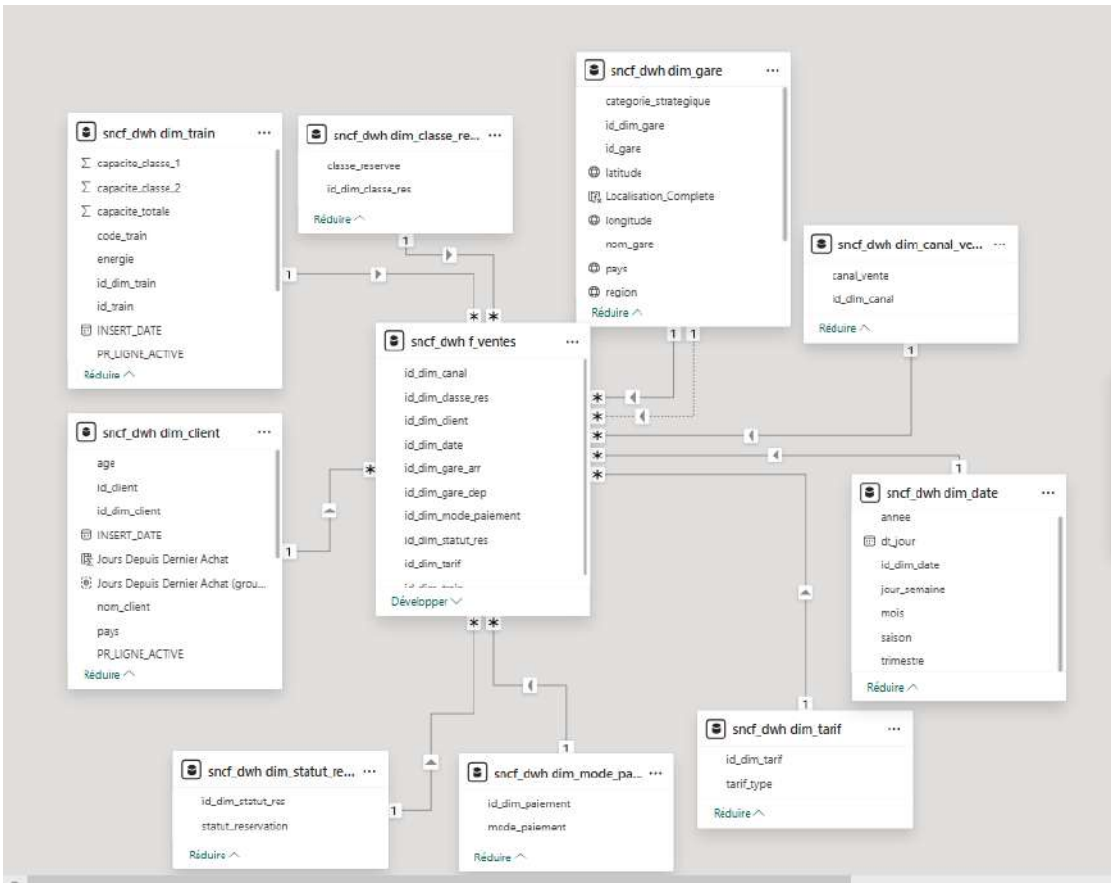
Cette architecture permet de bénéficier de la flexibilité de Power BI pour la conception de dashboards dynamiques tout en exploitant la structure optimisée du schéma en étoile conçu précédemment. Ce chapitre détaille donc la phase de restitution visuelle, où les données nettoyées et modélisées deviennent des actifs stratégiques. L'objectif est double : d'une part, assurer une visibilité en temps réel sur la performance financière et opérationnelle de la SNCF, et d'autre part, offrir une interface interactive permettant aux décideurs d'explorer les segments de clientèle et l'impact des annulations grâce à des indicateurs de performance (KPI) visuels et intuitifs.

## 1. Conception des Dashboards et KPI stratégiques

- **Modélisation et structuration des données**

La première étape cruciale de notre travail sous Power BI a consisté à importer notre base de données issue du Data Warehouse MySQL. Une fois les données chargées, nous avons scrupuleusement configuré les relations entre nos différentes tables afin de construire un **modèle compact et cohérent**, respectant l'architecture en étoile définie lors de la phase de conception.

Comme illustré dans notre modèle de données ci-dessous, la table de faits centrale (f_ventes) est reliée à ses dimensions (dim_client, dim_gare, dim_train, dim_date, etc.) par des relations de type "un-à-plusieurs" (1:*). Cette structure optimisée garantit l'intégrité référentielle et permet une propagation fluide des filtres à travers l'ensemble des rapports, assurant ainsi une analyse multidimensionnelle précise et performante.




- **Implémentation des mesures et Indicateurs de Performance (KPI)**

La puissance analytique de Power BI réside dans l'utilisation du langage **DAX (Data Analysis Expressions)**. Contrairement aux colonnes calculées, les **mesures** sont évaluées dynamiquement en fonction des filtres appliqués sur le rapport (contexte de filtre). Nous avons développé un ensemble de mesures clés permettant de traduire les données transactionnelles en indicateurs stratégiques, regroupés selon les axes financiers, opérationnels et clients.

Le tableau suivant synthétise les principaux indicateurs implémentés, leurs formules DAX respectives et leur utilité dans le processus de décision :

| **Nom du KPI** | **Formule DAX** | **Utilité / Aide à la décision** |
|---|---|---|
| Nombre de Réservations | COUNT(id_reservation) | Mesure le volume d'activité global de la période. |
| Chiffre d'Affaires | SUM(montant_total) | Indicateur de performance financière brute. |
| Total Passagers | SUM(nbr_passagers) | Évalue la fréquentation réelle des trains. |

| | | |
|---|---|---|
| Prix Billet Moyen | CA / Total Passagers | Analyse la rentabilité par voyageur. |
| Nombre Annulations | CALCULATE(DISTINCTCOUNT, Statut="Annulée") | Quantifie le volume de transactions perdues. |
| Taux d'Annulation | Nb Annulations / Nb Total Réservations | Mesure la volatilité et la fiabilité des réservations. |
| CA Perdu | CALCULATE(CA, Statut="Annulée") | Évalue l'impact financier direct du manque à gagner. |
| Fréquence d'achat | Nb Réservations / Nb Clients Distincts | Mesure la fidélité et l'engagement de la clientèle. |
| Revenu Moyen par Client | CA / Nb Clients Distincts | Identifie la valeur monétaire moyenne générée par client. |

- **Enrichissement du modèle : Colonnes calculées, Groupements et Tables techniques**

Pour affiner nos analyses et permettre des visualisations avancées, nous avons procédé à un enrichissement de notre modèle de données via trois types d'interventions :

- **Création d'une colonne calculée pour la fidélité**

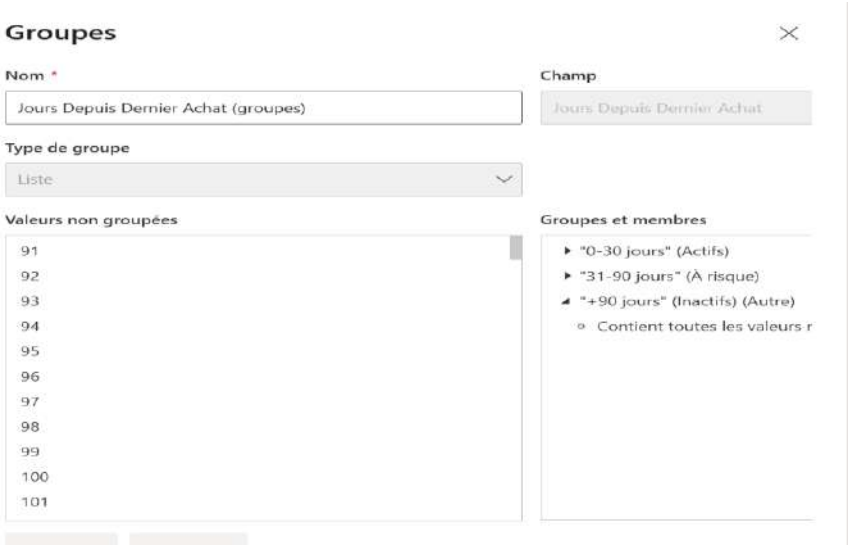
Afin d'analyser la récence d'achat, nous avons développé une colonne calculée Jours Depuis Dernier Achat en langage DAX. Cette colonne utilise la fonction DATEDIFF pour mesurer l'écart entre la date de la dernière transaction d'un client et la date maximale présente dans notre référentiel temporel.

```
1 Jours Depuis Dernier Achat = DATEDIFF('sncf_dwh f_ventes'[Date Dernier  Achat],MAX('sncf_dwh dim_date'
  [dt_jour]), DAY)
```

- **Segmentation par groupes de récence**

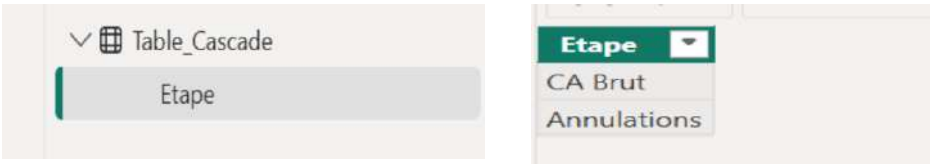
À partir de la colonne calculée précédemment, nous avons créé des **Groupes** de données pour catégoriser nos clients selon leur profil d'activité. Cette segmentation permet de distinguer visuellement trois segments stratégiques dans nos graphiques :

- **Actifs :** de 0 à 30 jours.
- **À risque :** de 31 à 90 jours.
- **Inactifs :** plus de 90 jours.




- **Table technique pour le graphique en cascade (Waterfall)**

Pour réaliser la réconciliation entre le Chiffre d'Affaires Brut et le Chiffre d'Affaires Net (page "Analyse des Annulations"), nous avons dû créer une table manuelle nommée Table_Cascade. Cette table contient une colonne Etape avec les valeurs "CA Brut" et "Annulations". Elle sert de base structurelle au visuel de cascade pour isoler et afficher la décomposition des flux financiers.

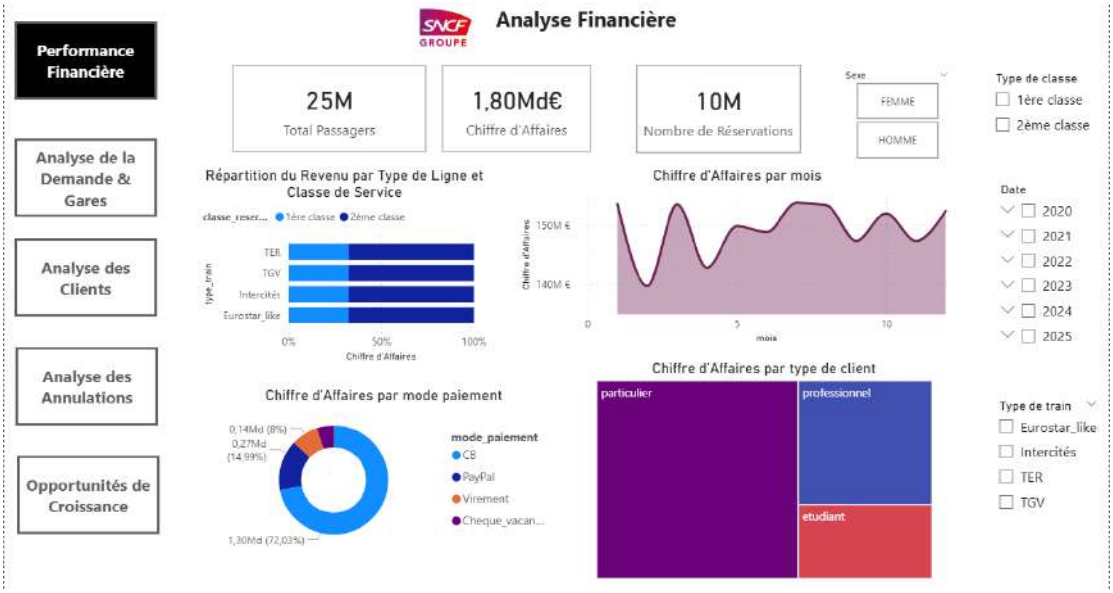



# 2. Conception et interprétations des Dashboards

Cette section présente les différents rapports interactifs conçus pour répondre aux besoins de pilotage de la SNCF. Chaque page a été pensée pour offrir une lecture progressive, allant des indicateurs globaux vers une analyse granulaire des données.

- **Page 1 : Analyse de la Performance Financière**

Cette première page constitue le tableau de bord exécutif du projet. Elle offre une vue d'ensemble sur la santé économique de l'activité ferroviaire à travers des indicateurs de haut niveau et des axes de segmentation stratégiques.




- **Indicateurs de Performance (KPIs) et Filtres**

En partie supérieure, trois cartes de données (Scorecards) résument les volumes globaux pour la période sélectionnée :

- **Total Passagers (25M) :** Représente le flux global de voyageurs transportés.
- **Chiffre d'Affaires (1,80 Md€) :** Indique la valeur monétaire totale des ventes.
- **Nombre de Réservations (10M) :** Quantifie le volume total de transactions effectuées.

Sur la droite, un volet de **Filtres interactifs** (Slicers) permet de naviguer dans la donnée selon plusieurs dimensions :

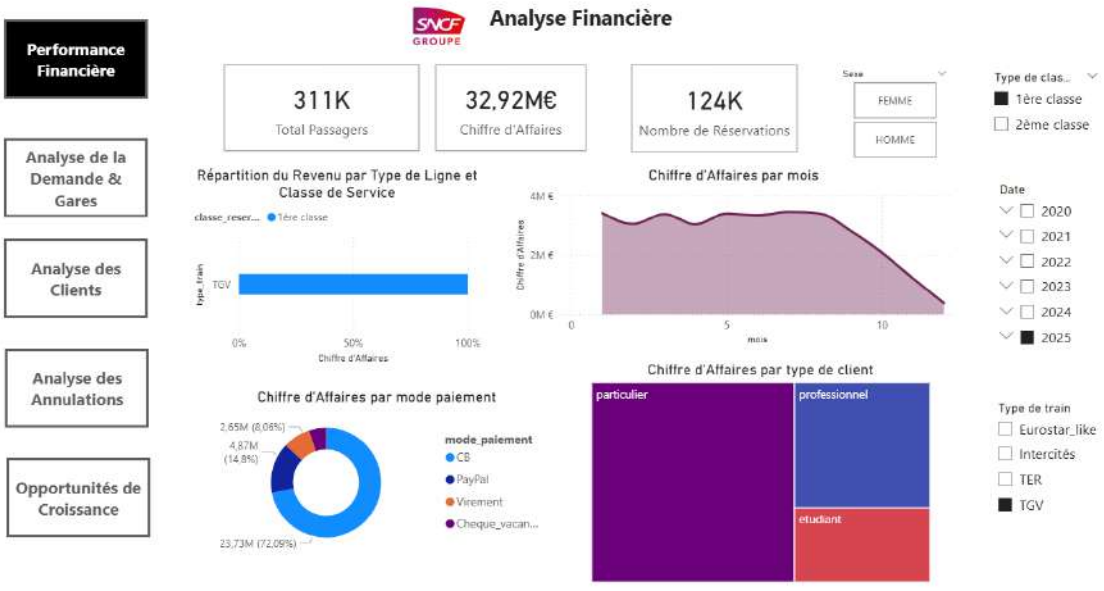
- **Sexe :** Sélection entre "FEMME" et "HOMME".
- **Type de classe :** Comparaison entre la 1ère et la 2ème classe.
- **Date :** Sélection temporelle par année, de 2020 à 2025.
- **Type de train :** Filtre par catégorie de ligne (Eurostar_like, Intercités, TER, TGV).

- **Analyse Visuelle de la Distribution du Revenu**

Le corps du rapport se décompose en cinq visuels complémentaires :

- **Répartition du Revenu par Type de Ligne et Classe :** Un graphique à barres empilées 100% qui montre la contribution de chaque classe de service (1ère et 2ème) au sein de chaque type de train (TER, TGV, etc.).
- **Chiffre d'Affaires par mois :** Un graphique en aires (Area Chart) retraçant l'évolution temporelle du CA, permettant de visualiser les tendances cycliques et les pics de saisonnalité sur une échelle de 12 mois.
- **Chiffre d'Affaires par mode de paiement :** Un graphique en anneau (Donut Chart) identifiant les habitudes de règlement des clients, où la **Carte Bancaire (CB)** domine avec **72,03 %** des transactions.
- **Chiffre d'Affaires par type de client :** Une carte proportionnelle (Treemap) segmentant le revenu par catégorie d'usager : Particulier, Professionnel et Étudiant. Le segment **Particulier** occupe visuellement la part la plus importante du CA.

- **Filtre : TGV en 1ère Classe (Année 2025)**

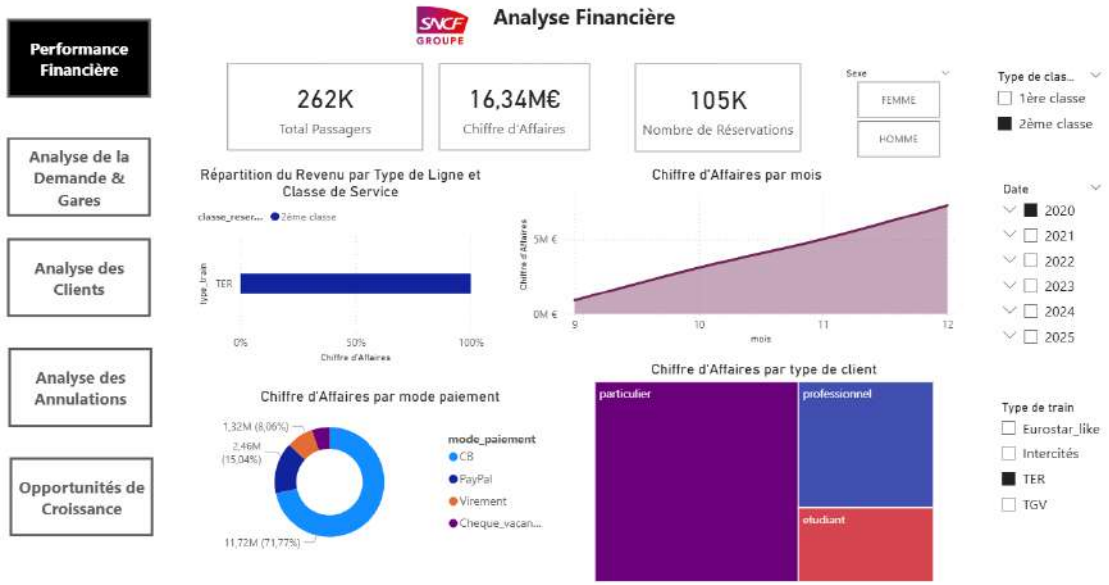



En sélectionnant uniquement le **TGV**, la **1ère classe** et l'année **2025**, les indicateurs se mettent à jour pour isoler ce segment premium :

- **Total Passagers (311K) :** On observe une réduction logique du volume par rapport aux 25M globaux. Ce chiffre représente la niche des voyageurs ayant choisi le confort maximal sur les lignes à grande vitesse en 2025.

- **Chiffre d'Affaires (32,92 M€) :** Malgré un volume de passagers plus faible, le CA reste significatif, ce qui confirme la valeur élevée du billet moyen dans ce segment.
- **Nombre de Réservations (124K) :** Ce KPI indique que chaque réservation pour ce segment concerne en moyenne **2,5 passagers** (311K / 124K), montrant une tendance aux voyages de groupe ou familiaux, même en 1ère classe.

- **Filtre : Mobilité Régionale (TER) en 2ème Classe (Année 2020)**



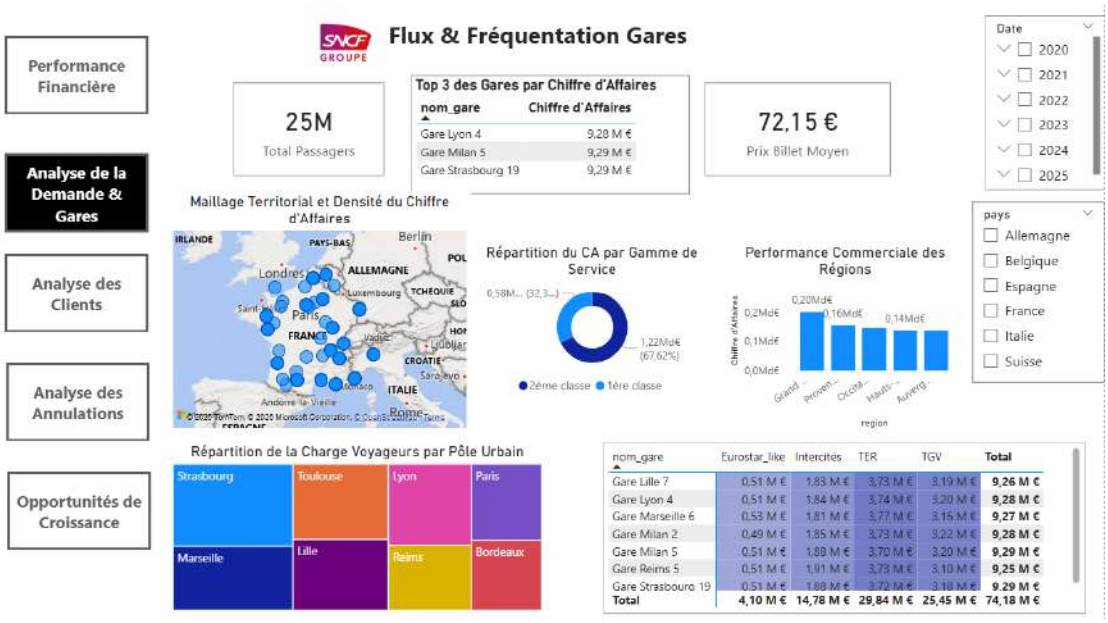

Ce scénario illustre parfaitement l'impact de la crise sanitaire sur les habitudes de transport, tout en isolant le service de proximité :

- **Total Passagers (262K)** : On remarque un volume de passagers plus faible que pour le scénario TGV précédent, ce qui peut paraître surprenant pour du TER, mais s'explique par les restrictions de déplacement strictes en 2020.
- **Chiffre d'Affaires (16,34 M€)** : Le CA est presque divisé par deux par rapport au scénario TGV de 2025, soulignant le prix plus bas du billet TER et la baisse de fréquentation globale.
- **Nombre de Réservations (105K)** : Ce chiffre confirme un usage très régulier avec environ **2,5 passagers par réservation**, montrant que même en période de crise, le TER reste un lien essentiel pour les petits groupes ou les familles.
- **Courbe mensuelle (Chiffre d'Affaires par mois)** : C'est le visuel le plus parlant. La courbe commence très bas en septembre pour monter progressivement jusqu'en

décembre. Cela reflète probablement la reprise très lente des déplacements après les confinements du début d'année 2020.

- **Page 2 : Analyse de la Demande & Gares**

L'objectif de cette page est de cartographier la performance commerciale et d'identifier les pôles d'attractivité du réseau ferroviaire. Elle permet de visualiser la répartition spatiale du Chiffre d'Affaires et la densité des flux de voyageurs.




- **Indicateurs de Performance (KPIs) et Slicers spécifiques**

En haut du rapport, nous retrouvons deux indicateurs majeurs :

- **Total Passagers (25M)** : Rappel du volume global pour situer l'échelle des flux.
- **Prix Billet Moyen (72,15 €)** : Un nouvel indicateur qui permet d'évaluer la rentabilité unitaire par voyage sur l'ensemble du réseau.

Le panneau de filtres à droite s'enrichit d'une dimension géographique :

- **Pays** : Permet d'isoler les performances sur le réseau domestique (France) ou sur les liaisons internationales (Allemagne, Belgique, Espagne, Italie, Suisse)

- **Analyse de la Répartition Géographique et de la Charge**

Le dashboard utilise des visuels variés pour décomposer la performance par gare et par région

- **Maillage Territorial et Densité du CA (Carte)** : Une carte interactive utilisant la latitude et la longitude pour positionner chaque gare. La taille des bulles est proportionnelle au Chiffre d'Affaires, permettant d'identifier immédiatement les hubs les plus rentables.

- **Répartition du CA par Gamme de Service (Donut)** : Ce visuel montre que la **2ème classe** génère la majorité des revenus (**67,62 %**), confirmant un modèle économique basé sur le volume.

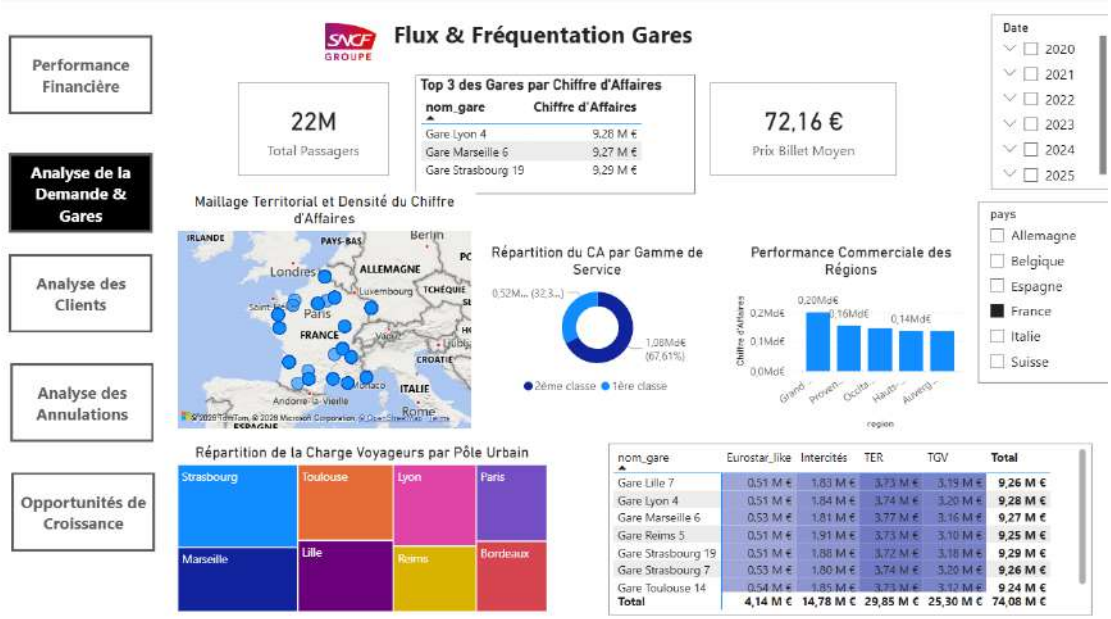
- **Performance Commerciale des Régions (Histo)** : Un graphique à barres classant les régions par CA. On y note la forte contribution du **Grand Est** et de **Provence-Alpes-Côte d'Azur**.

- **Répartition de la Charge Voyageurs par Pôle Urbain (Treemap)** : Ce visuel hiérarchique met en évidence les villes captant le plus de passagers, avec des pôles majeurs comme **Strasbourg**, **Toulouse**, **Lyon** et **Paris**.

- **Matrice de Performance par Gare (Tableau de bord)** : Un tableau croisé détaillé présentant le CA par gare et par type de train (Eurostar_like, Intercités, TER, TGV). Il offre une lecture précise de la spécialisation de chaque gare (ex: dominance du TER à Strasbourg ou du TGV à Lyon).

- **Filtre : Focus Marché France**

En isolant uniquement le pays **France** dans le panneau des filtres, vous mettez en évidence la suprématie du réseau national :



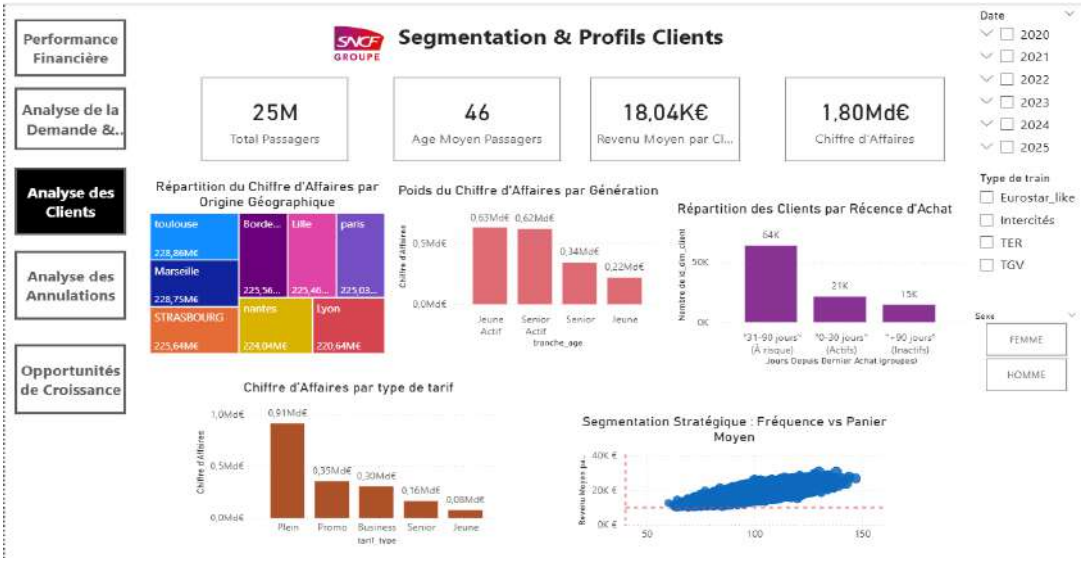

- **Total Passagers (22M) :** Sur les 25M de passagers globaux, la France en capte à elle seule **88%**, confirmant sa position de contributeur majeur au volume de trafic.
- **Prix Billet Moyen (72,16 €) :** Cet indicateur reste extrêmement stable par rapport à la vue globale (72,15 €), ce qui montre que les tarifs pratiqués sur le réseau français dictent la moyenne générale de l'entreprise.
- **Top 3 des Gares par CA :** Le classement est exclusivement français avec la **Gare Lyon 4** (9,28 M€), la **Gare Marseille 6** (9,27 M€) et la **Gare Strasbourg 19** (9,29 M€), soulignant l'importance des métropoles régionales dans la génération de revenus.

- **Évidence de la contribution nationale**
- **Performance Commerciale des Régions :** Le graphique en barres montre que le **Grand Est** est la région leader avec un CA de **0,20 Md€**, suivie de près par la région **Provence-Alpes-Côte d'Azur**. Cela démontre une répartition du chiffre d'affaires équilibrée entre les différents pôles économiques du pays.

- **Maillage Territorial :** La densité des points bleus sur la carte de France illustre la couverture complète du territoire, confirmant que l'infrastructure est optimisée pour desservir aussi bien les grandes lignes (TGV) que les trajets de proximité (TER).
- **Répartition par Gamme :** On observe que la **2ème classe** reste le moteur de la rentabilité française avec **67,61%** du CA, validant une stratégie de transport de masse accessible.

### • Page 3 : Segmentation & Profils Clients

Cette page est dédiée à l'analyse socio-démographique et comportementale des voyageurs. Elle permet de répondre aux questions : "Qui sont nos clients ?", "Quelle est leur valeur ?" et "Sont-ils fidèles ?".




- **Indicateurs de Performance (KPIs) de Profilage**

Quatre indicateurs clés sont mis en avant pour définir le portrait-robot de la clientèle :

- **Total Passagers (25M)** : Pour garder la cohérence du volume global.
- **Âge Moyen Passagers (46 ans)** : Un indicateur crucial qui montre une clientèle mature et active.
- **Revenu Moyen par Client (18,04K €)** : (ou Panier Moyen Client) Évalue la contribution financière moyenne de chaque individu sur la période.
- **Chiffre d'Affaires (1,80 Md€)** : Rappel de la performance financière totale.

- **Analyse Comportementale et Segmentation**

Le dashboard utilise des visuels avancés pour segmenter la base client :

- **Répartition du CA par Origine Géographique (Treemap)** : Ce visuel montre que le revenu est très équilibré entre les grandes métropoles (Toulouse, Marseille, Strasbourg, etc.), avec une contribution proche de **225 M€** par ville majeure.

- **Poids du CA par Génération (Histo)** : Segmente le revenu par tranche d'âge. On y voit que les **"Jeunes Actifs"** et **"Seniors Actifs"** sont les moteurs principaux du CA (plus de 0,6 Md€ chacun).

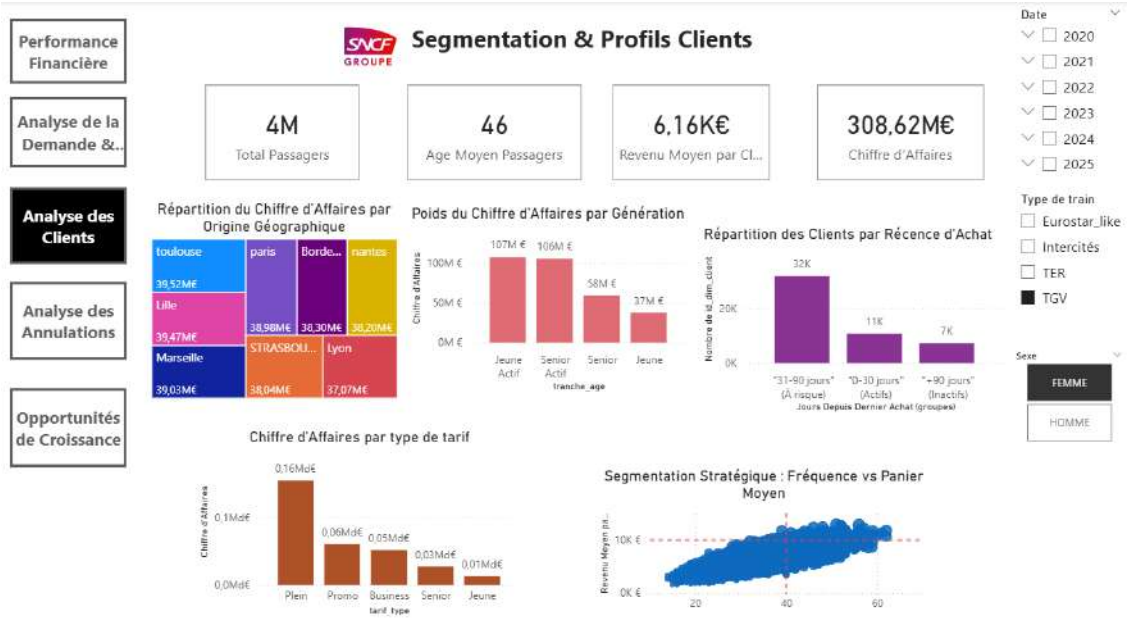
- **Répartition des Clients par Récence d'Achat (Groupes)** : Ce visuel utilise les **groupes DAX** créés précédemment. Il révèle qu'une grande partie des clients (64K) est dans la catégorie **"À risque"** (31-90 jours sans achat), soulignant un enjeu de fidélisation.

- **Chiffre d'Affaires par type de tarif** : Montre la dominance du tarif **"Plein"** (0,91 Md€) par rapport aux tarifs réduits (Promo, Senior, Jeune), ce qui indique une faible dépendance aux promotions pour générer du revenu.

- **Segmentation Stratégique : Fréquence vs Panier Moyen (Nuage de points)** : C'est le visuel le plus avancé de la page. Chaque point représente un client. On y observe une corrélation positive : plus un client voyage fréquemment, plus son panier moyen est élevé. La forte concentration de points au centre permet d'identifier le **"Client Type"** de la SNCF.

- **Filtre : Segment Féminin sur les lignes TGV**

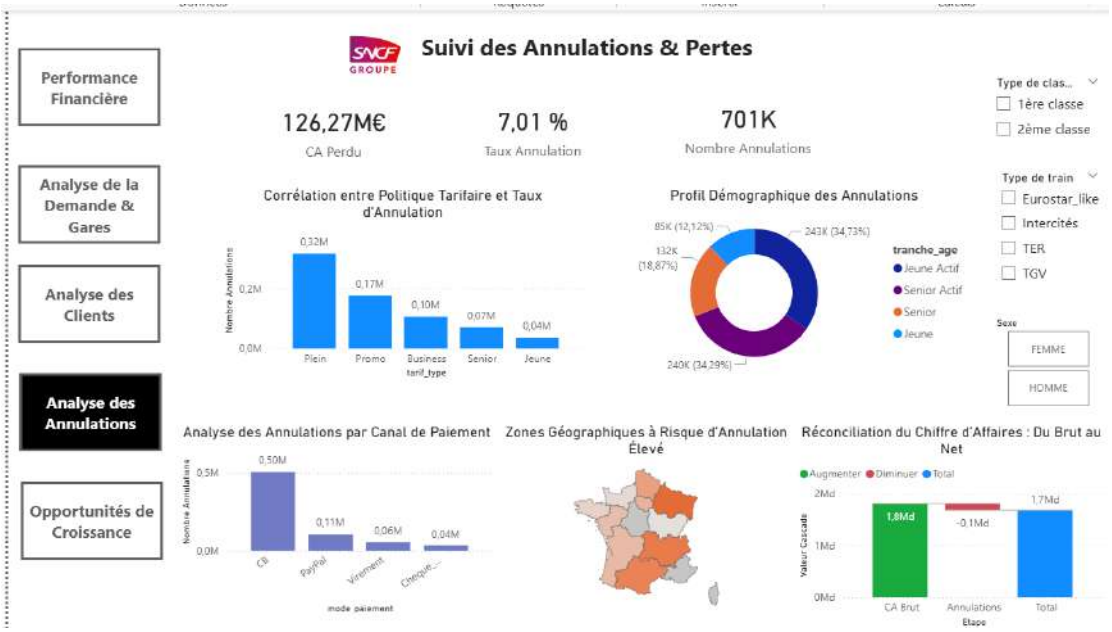
En croisant ces deux dimensions, le dashboard révèle les caractéristiques de ce segment de marché :




- **Total Passagers (4M) :** Sur les 25M de passagers globaux, les femmes voyageant en TGV représentent une part importante du trafic total.
- **Âge Moyen Passagers (46 ans) :** L'âge moyen reste identique à la moyenne globale, confirmant une clientèle mature et professionnellement établie pour ce segment.
- **Revenu Moyen par Client (6,16K €) :** On observe que le revenu moyen par cliente pour ce segment spécifique est inférieur à la moyenne globale (18,04K €), ce qui peut indiquer une fréquence de voyage plus ponctuelle ou l'utilisation de tarifs spécifiques.
- **Chiffre d'Affaires (308,62 M€) :** Ce segment génère à lui seul plus de 300 millions d'euros, soulignant son importance stratégique pour la rentabilité des lignes à grande vitesse.

- **Page 4: Analyse des Annulations**

Cette page fournit une vision consolidée des manques à gagner. Elle permet de quantifier précisément l'impact des annulations sur le chiffre d'affaires global avant d'orienter les politiques de remboursement.




✓ **Indicateurs de Pertes Globaux (KPIs)**

Sur l'ensemble du périmètre de données, les pertes se chiffrent ainsi :

- **CA Perdu (126,27 M€) :** Ce montant représente la perte sèche cumulée sur la période.
- **Taux Annulation (7,01 %) :** Un indicateur de santé opérationnelle qui montre que l'entreprise conserve plus de 92 % de ses réservations initiales.
- **Nombre Annulations (701K) :** Le volume total de transactions annulées, traitées par le système.

✓ **Segmentation et Analyse des Causes**

- **Corrélation Politique Tarifaire / Annulations :** Le graphique montre une forte corrélation entre la flexibilité des billets et le volume d'annulation. Le tarif **"Plein"** enregistre le plus haut niveau d'annulations (**0,32M**), suivi du tarif **"Promo"** (**0,17M**).
- **Profil Démographique (Donut) :** Les annulations sont principalement portées par les **"Jeune Actif"** (34,73 %) et les **"Senior Actif"** (34,29 %), reflétant les segments de clientèle les plus mobiles et dont les agendas sont les plus susceptibles de changer.

- **Canal de Paiement :** Le mode **CB** concentre la majorité des annulations avec **0,50M** de transactions, ce qui est proportionnel à son usage comme mode de paiement principal.
- **Répartition Géographique :** La carte de France met en évidence des zones de tension où le taux d'annulation est plus soutenu (zones orange), permettant un pilotage régionalisé des pertes

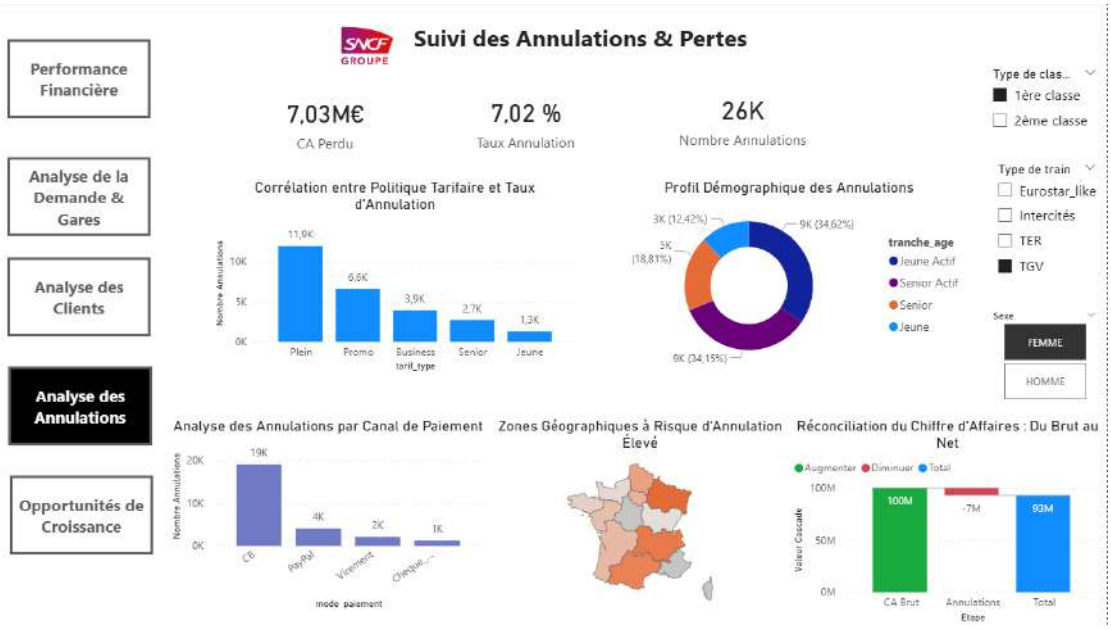
✓ **Réconciliation Financière et Interactivité**

Le graphique en cascade (Waterfall) assure la **Réconciliation du Chiffre d'Affaires** :

- Il illustre le passage du **CA Brut (1,8 Md€)** au **CA Net (1,7 Md€)** après déduction des **Annulations (-0,1 Md€)**.
- **Démonstration de l'interactivité (référence à l'image précédente) :** Comme illustré lors de nos tests précédents (filtre **Femme** et **TGV 1ère classe**), l'application de filtres croisés permet de recalculer instantanément ces pertes pour des segments spécifiques, offrant ainsi une granularité d'analyse indispensable pour le contrôle de gestion.

✓ **Filtre : Annulations du Segment Féminin Premium (TGV, 1ère classe)**

Ce scénario met en lumière la fragilité des réservations haut de gamme pour la clientèle féminine :

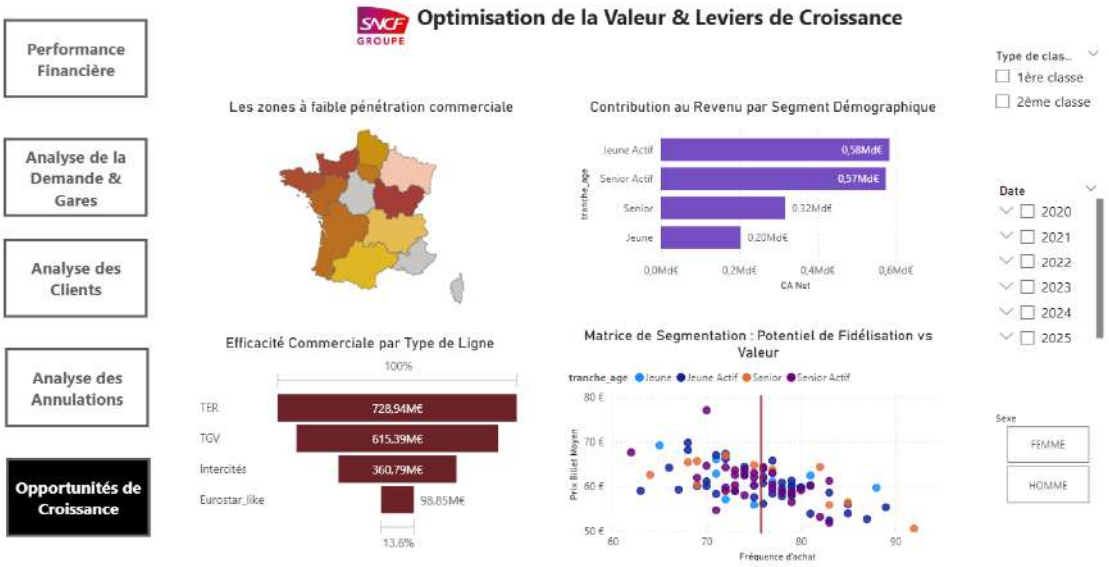



- **CA Perdu (7,03 M€) :** Ce montant représente le manque à gagner direct pour ce segment spécifique, un chiffre non négligeable pour une niche premium.

- **Taux Annulation (7,02 %) :** Ce taux est légèrement supérieur à la moyenne globale constatée sur la page sans filtre (7,01%), indiquant une volatilité un peu plus forte des réservations dans ce segment.
- **Nombre Annulations (26K) :** Volume total de billets annulés par les femmes voyageant en 1ère classe sur les lignes TGV.

- **Page 5 : Opportunités de Croissance**

Cette page finale synthétise les performances pour mettre en lumière les leviers stratégiques d'optimisation de la valeur client et du maillage territorial.




✓ **Analyse du Potentiel Géographique et Démographique** Le dashboard croise la localisation et le profil client pour détecter des zones de croissance :

- **Les zones à faible pénétration commerciale (Carte)** : Une carte choroplèthe de la France identifie les régions où le chiffre d'affaires est le moins élevé (couleurs sombre). Ces zones représentent des opportunités pour de nouvelles campagnes de conquête ou l'ouverture de lignes.
- **Contribution au Revenu par Segment Démographique (Barres)** : Ce visuel confirme que les **Jeune Actif (0,58 Md€)** et **Senior Actif (0,57 Md€)** sont les piliers actuels du CA Net. Il suggère également un potentiel de croissance sur les segments **Senior (0,32 Md€)** et **Jeune (0,20 Md€)**, actuellement en retrait.

✓ **Efficacité Opérationnelle et Segmentation Valeur**

**Efficacité Commerciale par Type de Ligne (Entonnoir)** : Ce graphique en entonnoir (Funnel) classe la rentabilité par type de train. Le **TER** mène avec **728,94 M€**, suivi du **TGV** à **615,39 M€**. La base de l'entonnoir montre que l'**Eurostar_like** (**98,85 M€**) reste une niche à fort potentiel de développement.

**Matrice de Segmentation : Potentiel de Fidélisation vs Valeur (Nuage de points)** : Ce visuel stratégique croise la **Fréquence d'achat** avec le **Prix Billet Moyen**.

- Les points situés en haut à droite représentent les clients à haute valeur et haute fidélité (essentiellement des **Senior Actif** et **Jeune Actif**).
- Les points à gauche de la ligne rouge identifient les clients à fidéliser, où une augmentation de la fréquence d'achat pourrait significativement booster le CA global.

✓ **Synthèse Décisionnelle & Orientations Stratégiques**

L'analyse transversale des cinq pages du dashboard permet de dégager des axes prioritaires pour la direction. L'objectif est de passer de la constatation (le "Quoi") à l'action (le "Comment").

✓ **Optimisation du CA et Gestion des Pertes**

L'analyse croisée de la **Performance Financière** et des **Annulations** révèle un point de vigilance majeur :

- **Constat :** Le segment premium (1ère classe) affiche un taux d'annulation de **7,02 %**, générant une perte sèche de plus de **44 M€** pour cette seule catégorie.
- **Décision préconisée :** Réviser les conditions de remboursement des billets "Plein Tarif". Une politique de frais d'annulation dégressifs selon la proximité du départ pourrait stabiliser le Chiffre d'Affaires Net.

✓ **Fidélisation et Segmentation Marketing**

La page **Segmentation & Profils Clients** met en lumière une fragilité dans la rétention :

- **Constat :** Une part critique de la clientèle (64K individus) est classée dans le groupe **"À risque"** (31-90 jours sans achat).
- **Décision préconisée :** Lancer des campagnes de marketing direct (push notifications, emails personnalisés) ciblant spécifiquement les **Jeunes Actifs** et **Seniors Actifs**, qui sont les plus gros contributeurs au CA mais aussi les plus sujets aux annulations.

✓ **Redynamisation du Maillage Territorial**

La page **Opportunités de Croissance** identifie des disparités géographiques :

- **Constat :** Certaines régions affichent une faible pénétration commerciale malgré une infrastructure existante (zones claires sur la carte).
- **Décision préconisée :** Mettre en place des tarifs "découverte" ou des partenariats locaux dans ces zones pour augmenter la charge voyageuse des lignes **TER**, qui possèdent déjà la meilleure efficacité commerciale globale (**728,94 M€**).

✓ **Stratégie de Pricing et Valeur Client**

La **Matrice de Segmentation** (Fréquence vs Panier Moyen) permet de définir une nouvelle approche tarifaire :

- **Constat :** Le prix du billet moyen stagne autour de **72,15 €**, avec une forte concentration de clients à fréquence moyenne.
- **Décision préconisée :** Introduire un programme de fidélité par paliers pour pousser les clients "Occasionnels" vers le quadrant "Ambassadeurs" (haut de droite), augmentant ainsi la LTV (*Lifetime Value*) globale.

# Chapitre 7 : Conclusion et Perspectives

L’achèvement de ce projet marque la mise en place d'une chaîne décisionnelle complète et performante, capable de répondre aux défis complexes du secteur ferroviaire. L’objectif central de ce travail était de transformer un gisement massif de dix millions de lignes de données brutes en un véritable actif stratégique pour la SNCF. Pour y parvenir, nous avons déployé une architecture de Business Intelligence de bout en bout, garantissant la fiabilité de l'information depuis sa source jusqu'à sa visualisation finale.

La réussite de cette implémentation repose sur une synergie rigoureuse entre plusieurs outils leaders du marché. Le processus a débuté par une phase cruciale d'intégration et de normalisation via Talend, permettant de structurer un Data Warehouse MySQL cohérent. Cette fondation a ensuite été consolidée par une migration vers SQL Server, assurant une intégrité référentielle stricte avant de passer à l'étape de l'intelligence multidimensionnelle. Grâce à la création de cubes sous SSAS et à l'exploitation des hiérarchies, nous avons offert une capacité d'analyse granulaire inédite. Le passage du langage SQL au MDX a radicalement transformé l'expérience analytique : là où les requêtes traditionnelles s'avéraient lourdes et chronophages sur de tels volumes, le cube permet désormais une exploration instantanée par simple manipulation visuelle.

L’aboutissement visuel sous Power BI a permis de traduire ces calculs complexes en indicateurs de performance intuitifs. L'utilisation du langage DAX a été déterminante pour piloter la santé financière, segmenter finement la clientèle et quantifier avec précision l'impact des annulations, qui s'élève à plus de 126 millions d'euros. Cette visibilité à 360 degrés permet aujourd'hui d'identifier des leviers de croissance concrets, notamment par la fidélisation des segments "Actifs" et l'optimisation des tarifs sur les lignes à forte volatilité.

En guise d'ouverture, ce modèle robuste constitue une base idéale pour des évolutions futures. La structure que nous avons conçue est totalement agnostique et pourrait être exploitée sur d'autres plateformes de pointe comme Tableau Software pour approfondir l'analyse exploratoire. L'avenir de ce projet réside également dans l'industrialisation sur le Cloud et l'intégration de modèles de Machine Learning. Ces technologies permettraient de passer d'une analyse descriptive à une analyse prédictive, capable d'anticiper les comportements des voyageurs et de simuler l'impact des stratégies commerciales avant même leur mise en œuvre.